

分类号_____

密 级_____

U D C _____

编 号_____

中南财经政法大学

硕 士 专 业 学 位 论 文

基于气象动态图卷积网络的汉江 水质参数预测研究与应用

研 究 生 姓 名： 费 子 奇

校内导师姓名、职称： 刘 妍 君 讲 师

申 请 者 类 型： 非 专 项 计 划

申请者学习方式： 全 日 制

学 科 门 类： 工 学

专 业 名 称： 大数据技术与工程

研 究 方 向： 无

入 学 时 间： 二〇二四年九月

二零二六年三月二十

Research and Application of Water Quality Parameter Prediction for the Hanjiang River Based on Meteorological Dynamic Graph Convolutional Networks

By Fei Ziqi

2026-03

中南财经政法大学学位论文独创性声明和使用授权声明

学位论文独创性声明

本人所呈交的学位论文，是在导师的指导下，独立进行研究所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品。对本文的研究做出重要贡献的个人和集体，均已在文中标明。

本声明的法律后果由本人承担。

论文作者（签名）：

年 月 日

学位论文使用授权书

本论文作者完全了解学校关于保存、使用学位论文的管理办法及规定，即学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权中南财经政法大学将本学位论文的全部或部分内容编入有关数据库，也可以采用影印、缩印或扫描等复制手段保存或汇编本学位论文。

注：保密学位论文，在解密后适用于本授权书。

论文作者（签名）：

年 月 日

摘 要

流域水质变化过程受自然环境条件与人类活动的共同影响,具有显著的时间非平稳性和空间异质性。准确预测流域水质变化对于水环境治理、水资源管理以及生态风险预警具有重要意义。然而,在数据挖掘与时空序列分析框架下,传统水质预测方法多依赖线性假设或单站点建模,难以有效刻画多站点水质数据之间复杂的时空依赖关系,且对降雨、径流等气象水文因素的动态影响考虑不足,限制了预测精度的进一步提升。

针对上述问题,本文以汉江流域为研究对象,融合国家水质自动监测网络数据与 ERA5 气象再分析数据,提出了一种气象感知动态时空图卷积网络(MD-DySTGCN)。该模型通过引入气象驱动机制构建随时间动态演化的图结构,自适应刻画不同水文情景下监测站点间的空间依赖关系;同时采用参数独立的双塔时序编码网络与物理感知门控融合机制,实现了水质内在演化规律与气象外部驱动信息的有效解耦与协同建模。基于汉江流域 16 个国控断面的 9 项核心水质指标实测数据,本文开展了系统的多步长预测验证。实验结果表明,在水文条件最为复杂的下游宗关断面,MD-DySTGCN 展现出卓越的预测性能,其测试集均方根误差(RMSE)低至 0.2649,平均绝对百分比误差(MAPE)仅为 7.67%。相较于时空图网络与纯时序大模型,本模型的预测误差明显降低,且能敏锐捕捉由极端降雨径流事件引发的浊度等参数突变特征。此外,多维消融实验进一步证实了气象驱动、动态构图及门控融合等创新模块的物理合理性与有效性。

为推动算法理论的工程化落地应用,本文进一步设计并实现了一套基于大语言模型的汉江流域水质智能预警系统。系统全面封装了 MD-DySTGCN 的在线推演与多维可视化监控能力,并深度集成了基 ReAct 范式的智能体与检索增强生成技术。研究表明,气象驱动的动态图建模与大语言模型增强的智能交互相融合,实现了异常水情的自动感知研判与自然语言交互问询,为流域水环境精细化管理与应急决策提供了行之有效的技术路径。

关键词: 流域水质预测; 时空图神经网络; 动态图; 气象驱动; 智能预警系统

Abstract

The process of water quality variation in a river basin is jointly influenced by natural environmental conditions and human activities, exhibiting significant temporal non-stationarity and spatial heterogeneity. Accurate prediction of water quality changes is of great significance for water environment governance, water resource management, and ecological risk early warning. However, within the framework of data mining and spatio-temporal sequence analysis, traditional water quality prediction methods mostly rely on linear assumptions or single-station modeling. They struggle to effectively characterize the complex spatio-temporal dependencies among multi-station water quality data, and insufficiently consider the dynamic impacts of hydro-meteorological factors such as rainfall and runoff, which limits further improvements in prediction accuracy.

To address these issues, this paper takes the Hanjiang River Basin as the research object and proposes a Meteorology-aware Dynamic Spatio-Temporal Graph Convolutional Network (MD-DySTGCN) by integrating data from the national automatic water quality monitoring network and ERA5 meteorological reanalysis data. By introducing a meteorology-driven mechanism, the model constructs a dynamically evolving graph structure over time to adaptively depict the spatial dependencies between monitoring stations under different hydrological scenarios. Meanwhile, it employs a parameter-independent dual-tower temporal encoding network and a physics-aware gated fusion mechanism to achieve the effective decoupling and collaborative modeling of the intrinsic evolution laws of water quality and external meteorological driving information. Based on the measured data of nine core water quality indicators from 16 national monitoring sections in the Hanjiang River Basin, this paper conducts systematic multi-step prediction validations. Experimental results indicate that at the downstream Zongguan section, which has the most complex hydrological conditions, MD-DySTGCN demonstrates outstanding prediction performance. Its Root Mean Square Error (RMSE) on the test set is as low as 0.2649, and the Mean Absolute Percentage Error (MAPE) is only 7.67%. Compared with current mainstream spatio-temporal graph networks and advanced pure time-series large models, the prediction error of this model is significantly reduced, and it can keenly capture the abrupt mutation features of parameters such as turbidity triggered by extreme rainfall-runoff events. In addition, multi-dimensional ablation experiments further verify the physical rationality and effectiveness of innovative modules such as the meteorology-driven mechanism, dynamic graph construction, and gated fusion.

To promote the engineering application of the algorithm theory, this paper further designs and implements an intelligent early warning system for water quality in the Hanjiang River Basin based on Large Language Models (LLMs). The system comprehensively encapsulates the online inference and multi-dimensional visual

monitoring capabilities of MD-DySTGCN, and deeply integrates agents based on the ReAct paradigm and Retrieval-Augmented Generation (RAG) technology. The research shows that the integration of meteorology-driven dynamic graph modeling and LLM-enhanced intelligent interaction achieves automatic perception and judgment of abnormal water conditions, as well as natural language interactive inquiries, providing an effective technical pathway for the refined management and emergency decision-making of the basin's water environment.

Key Words: River basin water quality prediction; Spatio-temporal graph neural network; Dynamic graph; Meteorology-driven; Intelligent early warning system

目录

第 1 章 绪论	1
1.1 研究背景与意义	1
1.1.1 研究背景	1
1.1.2 研究意义	1
1.2 国内外研究现状	2
1.2.1 基于传统机理模型的研究	2
1.2.2 基于传统统计学习的研究	2
1.2.3 基于深度学习的研究	3
1.2.4 考虑空间关联与多源融合的研究现状	4
1.3 研究内容与技术路线	5
1.3.1 研究内容	5
1.3.2 本文的创新点	6
1.3.3 技术路线	6
第 2 章 相关理论	8
2.1 水质系统演变机理	8
2.1.1 多变量水质参数的耦合性	8
2.1.2 气象数据对水质的影响机理	8
2.1.3 大气再分析理论	9
2.2 时间序列预测模型理论基础	10
2.2.1 循环神经网络及其变体	10
2.2.2 时间卷积网络	11
2.3 图神经网络与空间建模	11
2.3.1 图数据的拓扑构建	12
2.3.2 谱域图卷积网络原理	12
2.3.3 图注意力网络	12
2.4 模型评价指标	13
2.4.1 均方根误差	13
2.4.2 平均绝对误差	13

2.4.3 决定系数	14
第 3 章 数据集构建与预处理	15
3.1 研究区域与多源数据概况	15
3.1.1 研究区域	15
3.1.2 水质参数数据	17
3.1.3 气象驱动数据	18
3.2 数据预处理	18
3.2.1 缺失值处理	19
3.2.2 异常值检测	20
3.2.3 数据归一化	21
3.3 气象数据时空对齐	22
3.3.1 空间对齐	22
3.3.2 时间对齐	23
第 4 章 基于动态时空图卷积的水质预测模型	24
4.1 气象驱动的动态邻接矩阵生成机制	25
4.1.1 动态构图的物理动机	26
4.1.2 气象驱动的状态节点嵌入建模	26
4.1.3 基于自注意力的动态邻接权重生成	27
4.1.4 物理先验约束与邻接矩阵规范化	27
4.2 基于双塔 TCN 的时序特征提取	28
4.2.1 TCN 结构配置与参数设置	28
4.2.2 残差结构与正则化策略	29
4.2.3 双塔 TCN 结构设计	29
4.3 动态图卷积与物理感知融合	31
4.3.1 多层动态图卷积	31
4.3.2 物理感知门控机制的水文解释	32
4.3.3 输出层设计与多步预测稳定性	33
第 5 章 实验和结果分析	35
5.1 实验设置	35
5.1.1 对比实验设计	35
5.1.2 消融实验设计	38

5.2 结果分析	39
5.2.1 训练过程分析	39
5.2.2 对比实验结果分析	41
5.2.3 消融实验结果分析	42
5.2.4 可视化分析	44
第 6 章 基于大语言模型的智能预警系统设计与实现	46
6.1 系统需求分析与总体框架设计	46
6.1.1 功能与非功能需求分析	46
6.1.2 总体框架设计	47
6.2 系统数据库设计	48
6.2.1 数据库概念结构设计	48
6.2.2 数据表逻辑结构设计	49
6.3 水质预测模块设计与实现	52
6.3.1 数据时空对齐与预处理接口	53
6.3.2 水质预测模型推理部署	54
6.4 智能预警 Agent 模块设计与实现	54
6.4.1 自动预警与研判分发机制	55
6.4.2 用户自然语言问询与深度分析机制	56
6.5 系统原型运行实例展示	56
6.5.1 汉江流域水质监控查询界面	57
6.5.2 水质参数预测分析看板	58
6.5.3 极端天气下的智能预警与 Agent 交互案例	59
第 7 章 总结和展望	61
7.1 研究总结	61
7.2 研究展望	62
参考文献	63

第 1 章 绪论

1.1 研究背景与意义

1.1.1 研究背景

流域水质演变是典型的多因子耦合时空过程，受自然条件与人类活动的共同影响，呈现出显著的时间非平稳性与空间异质性。准确预测水质变化趋势，对水环境风险预警、水资源科学调配及生态安全保障具有重要价值。

随着物联网技术的普及，汉江流域已建成覆盖干流主要断面的水质自动监测网络，积累了海量的多站点时序数据。与此同时，卫星遥感与气象再分析技术的发展，为从“水-气耦合”视角解析水质变化提供了高分辨率的外部驱动数据。如何挖掘这些多源异构数据中的时空演变规律，建立精准的水质预测模型，已成为大数据技术与环境科学交叉领域的前沿热点。

然而，现有预测方法多基于线性假设或单站点独立建模，难以刻画多站点间复杂的时空依赖关系。更重要的是，站点间的空间关联强度并非固定不变——在丰水期，强降雨引发的径流冲刷会显著增强上下游的污染输移；在枯水期，水体交换减弱，站点间关联随之降低。这种随水文条件动态变化的空间依赖性，是传统静态图网络难以有效建模的瓶颈问题，制约了预测精度的进一步提升。

1.1.2 研究意义

（1）理论意义

本研究从时空序列预测的视角出发，将流域水质预测抽象为多变量时空图建模问题，提出了一种气象感知动态图时空预测模型（MD-DySTGCN）。通过引入 ERA5 气象再分析数据构建动态邻接矩阵，使模型能够自适应刻画不同水文情景下站点间的空间依赖变化；通过双塔时间编码结构与物理感知门控融合机制，实现水质内在演化规律与气象外部驱动信息的协同建模。这一方法突破了现有研究多采用静态图结构的局限，为时变空间依赖关系的建模提供了具备物理可解释性的新技术路径，对推动时空图神经网络在非平稳环境下的应用具有理论参考价值。

（2）现实意义

汉江作为长江最大支流和南水北调中线工程的核心水源地，其水质状况直接关系到沿线数千万人口的饮水安全。本研究以汉江为实证对象，构建了覆盖 16 个监测断面的水质预测模型，在水文条件最为复杂的汉江下游宗关断面预测任务中展现出卓越的性能。实验表明，该模型的均方根误差（RMSE）低至 0.2649，平均绝对百分比误差（MAPE）仅为 7.67%。相较于当前先进的纯时序大模型（如 PatchTST），本模型的预测误差进一步显著降低了约 9.03%，并能有效捕捉受极端气象驱动引发的浊

度等参数突变特征。基于该算法开发的智能预警系统，实现了异常水情的自动感知研判与基于自然语言的主动交互问询，为环保部门提供了从数据感知到智能辅助决策的一站式平台，在水环境精细化管理中具有极强的工程应用价值。

1.2 国内外研究现状

1.2.1 基于传统机理模型的研究

机理模型基于质量守恒、动量守恒及化学动力学原理，通过构建描述污染物迁移、扩散及转化过程的微分方程组进行数值模拟。国内学者主要通过引进国外成熟模型（如 WASP、SWAT、MIKE 等）并进行本土化参数改良，广泛应用于流域水环境规划与管理中。

在国外研究方面，该领域侧重于模型的理论完善、大尺度扩展及不确定性分析。Gassman 等（2007）对 SWAT 模型的历史发展进行了系统回顾，证实了该模型在模拟复杂流域水文循环及农业化学物质（氮、磷、农药）迁移转化中的核心优势，确立了其在非点源污染评估中的主导地位。随着计算技术的进步，研究尺度逐渐向宏观拓展^[18]。Abbaspour 等（2015）构建了覆盖全欧洲的高分辨率 SWAT 模型，重点探讨了参数异质性与监测数据稀缺性带来的挑战，强调了利用 SWAT-CUP 等工具进行不确定性量化的必要性，为跨国界水资源管理提供了科学依据^[17]。

在国内研究方面，学者主要采取引进国外成熟模型（如 SWAT、MIKE、WASP 等）并进行本土化改良的策略。夏智宏等（2010）将 SWAT 模型应用于汉江流域，构建了分布式水文模拟体系，量化了降水和气温波动对径流的驱动作用，从机理层面验证了气象因子是驱动流域水文水质变化的关键变量^[2]。针对受水利工程强干扰的复杂河网，熊鸿斌等（2017）则利用 MIKE 11 模型强大的水动力耦合能力，对引江济淮工程背景下的涡河段进行了模拟，精确刻画了水流与污染物输移的动态关系，展示了商业化机理模型在复杂边界条件下的应用优势^[3]。

综上所述，尽管基于机理的模型在解释环境过程和评估管理措施方面表现优异，但其对高精度物理参数的依赖、复杂的校准过程以及在大尺度应用中的计算瓶颈，仍是当前研究面临的主要挑战。

1.2.2 基于传统统计学习的研究

随着水环境监测数据的积累和计算科学的发展，研究重点逐渐从线性统计模型转向具有更强非线性映射能力的机器学习模型。国内外学者在应用人工神经网络（ANN）、支持向量机（SVM）及随机森林（RF）等算法进行水质参数预测方面开展了大量研究。

在国外研究方面，机器学习方法较早被引入以解决水资源变量的非线性预测问题。Maier 和 Dandy（2000）对神经网络在水资源领域的应用进行了开创性的综述，指出

相比于传统统计模型,神经网络能够以任意精度逼近非线性函数,更适合处理复杂的水环境系统变量^[21]。近年来,随着算法的迭代,研究更趋向于模型的鲁棒性与关键因子的筛选。Mo 等(2024)在沿海城市的水质评估中应用了机器学习模型,通过筛选季节性关键水质参数,实现了对水质指数(WQI)的高效预测,证明了数据驱动模型在特定环境下的适应性^[20]。针对模型泛化能力问题,Abdessamad 等(2025)进一步提出了先进的机器学习组合模型,通过优化算法结构,显著提升了 WQI 预测的鲁棒性和分类准确率,代表了当前国际上利用机器学习进行水质综合评价的前沿水平^[19]。

在国内研究方面,学者们更关注算法在特定流域的本土化应用及模型参数的优化策略。针对长江流域复杂的降水与水文特征,徐志等(2023)构建了考虑协变量的随机森林(Random Forest)融合模型,利用随机森林优越的抗过拟合能力和特征重要性评估功能,有效提升了流域内水文要素的模拟精度,这也为汉江流域的水质预测提供了方法借鉴^[5]。此外,针对传统机器学习模型(如 SVM)参数选择困难、易陷入局部最优的问题,智能优化算法的应用成为热点。张雪芹(2022)探讨了利用改进粒子群算法(PSO)优化支持向量机(SVM)参数的方法,虽然该研究是针对软件缺陷预测,但其提出的 PSO-SVM 参数寻优框架在解决非线性回归问题上具有通用性,证实了通过群智能算法自动搜索最优超参数能显著提升传统机器学习模型的预测性能^[6]。

综上所述,传统统计学习与经典机器学习算法(如 RF, SVM, ANN)在处理非线性关系和静态特征映射方面已取得显著成果。然而,上述模型在处理具有长时序依赖性的水质时间序列数据时,往往缺乏对时间维度特征的深度挖掘能力,且对高维时空数据的并行处理效率较低。这为引入具有时序记忆功能和更强特征提取能力的深度学习模型(如 TCN、LSTM)提供了契机。

1.2.3 基于深度学习的研究

随着大数据技术的发展,深度学习因其强大的特征提取与非线性映射能力,逐渐取代传统机器学习,成为水质时间序列预测的主流方法。Li 等(2024)在 *Environmental Science and Pollution Research* 发表综述指出,深度学习模型能够有效捕捉水环境数据中复杂的时空依赖性,是解决高维、非平稳水质预测问题的关键技术手段^[15]。在具体模型应用上,长短期记忆网络(LSTM)及其变体(如 GRU)凭借其门控机制,解决了长序列训练中的梯度消失问题,被广泛应用于国内外研究中。然而,单一的 LSTM 模型往往难以达到最优效果,因此“混合模型”与“参数优化”成为研究热点。

在国外研究中,学者们致力于设计更复杂的混合架构以提升预测精度。Zhao 等(2024)提出了一种基于改进深度置信网络(DBN)与 LSTM 的混合模型,利用 DBN 进行无监督特征预提取,再结合 LSTM 进行时序预测,显著提升了模型的收敛速度和评估准确性^[13]。为了解决超参数寻优难题,Rajagopal 等(2024)引入了 COOT-CSO (Coot Bird Optimization - Cat Swarm Optimization)混合优化算法来自动调整 LSTM

的权重与偏置，该方法在多项环境水质指标预测中表现出了极高的鲁棒性^[12]。

在国内研究中，重点同样集中在数据预处理与模型优化的结合上。何欣（2022）针对河流水质数据的非平稳性，构建了 GA-VMD-LSTM 模型，首先利用变分模态分解（VMD）将复杂水质序列分解为多个平稳子序列，再利用遗传算法（GA）优化 LSTM 参数，有效降低了噪声对预测精度的干扰^[9]。罗文显（2024）也在其研究中验证了基于深度学习的时间序列技术在处理具有突变特征的水质数据时，相比传统统计模型具有显著的优越性^[10]。

为了解决长序列中的信息遗忘问题并挖掘站点间的空间联系，注意力机制（Attention Mechanism）与图神经网络（GCN）开始被引入水质预测领域。Zheng 等（2024）在 *Environmental Modelling and Software* 上提出了一种基于双重注意力机制（Dual-Attention）的预测方法，通过同时对输入特征维度和时间维度分配动态权重，实现了对关键水质参数和关键时间步的精准捕捉，特别是在“样本外（Out-of-sample）”预测场景下展现了优异的泛化能力^[14]。针对流域水系的拓扑结构，黎园园（2023）探索了多图卷积网络（Multi-GCN）在河流总磷预测中的应用，通过构建站点间的空间邻接矩阵，成功捕获了上下游站点间的空间协同变化规律，弥补了传统时间序列模型忽视空间信息的缺陷^[7]。

值得注意的是，为了克服纯数据驱动模型缺乏物理可解释性的弱点，物理引导的深度学习（PGDL）正成为国内前沿方向。黎煜昭等（2023）提出了一种基于物理约束的 GRU 神经网络，将对流扩散方程（ADE）作为损失函数的正则化项嵌入到 GRU 的训练过程中。该模型不仅保证了预测结果符合污染物迁移扩散的物理规律，还在训练数据稀缺的情况下保持了较高的预测精度^[8]。

1.2.4 考虑空间关联与多源融合的研究现状

当前的水质预测研究正从单一站点的独立模拟，向考虑流域空间关联与多源数据融合的综合建模方向转变。然而，如何有效利用河流网络的拓扑结构以及外部水文气象驱动数据，仍是提升模型泛化能力的关键挑战。

传统的深度学习模型（如 LSTM、TCN）通常将不同监测站点视为相互独立的个体，忽略了河流作为一个连续流体系统，上下游水质之间存在的显著滞后相关性。针对这一痛点，国内学者开始探索利用图神经网络（GNN）来显式建模河流的空间结构。陈志伟（2023）在哈尔滨工业大学的学位论文中，构建了基于时空图卷积网络（STGCN）的河流水质预测模型。该研究利用图论中的邻接矩阵描述了监测断面间的上下游拓扑关系，通过图卷积算子实现了空间特征的聚合，并结合时间卷积捕获时序演变。实验结果表明，考虑了空间协同作用的 STGCN 模型，在预测突发性水质变化时，其精度显著优于孤立的单站点预测模型^[11]。

除了空间维度的拓展，引入外部驱动数据（如气象、水文要素）也是提升模型物理可解释性的重要途径。Nearing 等（2021）在水资源领域顶级期刊 *Water Resources*

Research 上撰文探讨了水文科学在机器学习时代的角色,明确指出单纯的数据驱动模型容易忽略物理过程的约束。文章强调,为了构建更鲁棒的预测系统,必须将水文科学的先验知识(如降雨-径流关系、气象驱动机制)与深度学习算法进行深度融合,而非仅停留在黑盒预测层面^[23]。在具体的融合实践中,Chen 等(2024)以黄杨水库(Huangyang Reservoir)为例,研究了深度学习在多变量驱动下的水质预测性能。该研究通过整合水质历史数据与环境因子,构建了高精度的深度学习模型,验证了多源信息融合能够有效弥补单一水质数据在表征复杂水环境动态时的不足,为水库及河流管理提供了科学的决策支持^[22]。

综上所述,虽然 STGCN 等模型成功解决了空间建模问题,且学界已达成“融合水文气象数据”的共识,但在实际应用中,高质量气象驱动数据的获取仍是难点。现有研究多依赖稀疏的地面气象站插值,难以精细刻画流域尺度的气象强迫。这为本研究引入 ERA5 再分析数据(全球高分辨率气象数据集),并结合 TCN 强大的时序提取能力进行流域级水质预测提供了契机。

1.3 研究内容与技术路线

1.3.1 研究内容

本研究以汉江流域为实验对象,基于 2021-2025 年的 16 个水质监测站数据及 ERA5 气象再分析数据,重点开展以下工作:

(1) 流域多源数据的构建与时空对其

为开展流域水质预测研究,本研究首先对多源异构数据进行了系统治理。针对 16 个站点的 9 项核心水质监测数据,采用箱线图法剔除异常值,并设计了结合时间连续性与空间邻近性的分层差异化插补策略修复缺失数据,以确保序列的稳定性。在此基础上,引入 ERA5 高分辨率气象再分析数据(包括降雨、气温、风速、地表径流等),通过双线性插值与时间滑窗聚合算法,将网格化气象场精准映射至各离散监测断面,构建了“水质-气象”严格对齐的双流驱动时空数据集。

(2) 基于气象感知动态图时空卷积网络的预测模型构建

针对传统水质预测模型采用静态空间拓扑难以适应水文环境剧烈变化的瓶颈,本研究提出了 MD-DySTGCN 模型。在空间维度,突破了物理距离的刚性限制,设计了气象驱动的动态邻接矩阵生成机制,使其能根据降雨、径流等外部强迫自适应重构丰枯水期的空间拓拓扑权重。在时间维度,摒弃传统循环神经网络,设计了参数独立的双塔时间卷积网络以解耦水质内在惯性与气象驱动特征。最终,通过构建物理感知门控融合机制,动态评估气象脉冲对水质系统的冲击权重,实现了多源异质特征的深度物理协同建模。

(3) 复杂水文场景下的模型验证与机理分析

为全面评估所提模型的性能,本研究在水文条件最为复杂的汉江下游宗关断面开展了多步长预测验证。实验构建了包含传统统计学、纯时序大模型(如 PatchTST、Crossformer)以及时空图网络(如 Graph WaveNet、MTGNN)在内的 11 种基线模型对比体系。通过对 RMSE、MAPE 等稳健误差指标的量化评估,验证 MD-DySTGCN 模型在多站点水质预测任务中的精度优势与抗噪鲁棒性。同时,深入开展多维消融实验与可视化分析,定量解析气象驱动先验、动态图构图及门控融合等核心模块在捕捉极端天气水质突变特征中的物理机制与有效性。

(4) 基于大语言模型的水质智能预警系统设计与实现

为推动时空预测算法的工程化应用,本研究结合大数据与人工智能前沿技术,设计并实现了一套汉江流域水质智能预警系统。该系统全面封装了 MD-DySTGCN 算法的在线多步推演能力,并实现了流域拓扑与多维水质演变趋势的 Web 端动态可视化渲染。更重要的是,系统深度集成了基于 ReAct 范式的智能体与检索增强生成技术,打通了底层关系型数据库与专属知识向量库。实现了从水质异常的自动感知预警,到基于自然语言的用户主动交互问询,为流域精细化管理提供了“数据感知-算法推演-认知诊断”的一站式辅助决策平台。

1.3.2 本文的创新点

针对汉江流域水质演化过程中空间依赖关系受气象条件动态调制、传统静态图网络难以有效刻画的难题,本文在数据驱动建模框架下引入气象感知机制,提出了一种气象感知动态图时空预测模型(MD-DySTGCN)。该思路突破了现有研究多采用固定拓扑结构或简单特征拼接的局限,为提升非平稳水文条件下的流域水质预测精度提供了具备物理可解释性的新技术路径。其核心创新之处体现在以下两个维度的深度协同:

在空间拓扑动态建模方面,本研究将 ERA5 高分辨率气象再分析数据作为外部驱动变量,通过节点状态嵌入与自注意力机制计算空间相似度,并创新性地耦合了基于真实河网拓扑的物理先验约束。该机制使模型能够打破物理距离的静态限制,根据不同水文情景(如暴雨引发的径流冲刷或枯水期的水流滞留)自适应调整站点间的空间耦合强度,从而在严格遵循水动力学单向流特征的前提下,准确刻画污染物在丰枯水期的隐式输移规律。

在时空特征解耦与融合方面,针对异质变量在时间演化模式上的差异,本文摒弃了传统循环神经网络,设计了参数独立的双塔时间卷积网络以实现水质状态与气象驱动时序特征的深度解耦。在此基础上,进一步设计了物理感知门控融合机制,利用网络自适应评估气象脉冲对水质系统的非线性冲击权重,从而实现了水质内在惯性演化规律与外部气象突变强迫的协同建模。

1.3.3 技术路线




图 1-1 研究技术路线

第2章 相关理论

2.1 水质系统演变机理

2.1.1 多变量水质参数的耦合性

在水环境系统中，各类水质指标并非相互独立，而是通过复杂的物理、化学和生物生化过程相互交织与反馈。这种参数间的强耦合性是水质演变非线性特征的核心来源。具体而言，这种耦合关系主要体现在以下几个层面：首先，在物理化学过程方面，水温的波动直接决定了气体在水中的溶解度极限，水温升高不仅会导致溶解氧（DO）的物理逸散，还会加速水体中污染物的化学反应速率；同时，酸碱度（pH）的变化会显著影响氨氮、重金属等污染物的赋存形态与毒性。其次，在生物地球化学循环方面，有机污染物（如化学需氧量 COD、生化需氧量 BOD）的降解过程伴随着微生物的剧烈耗氧，这是导致水体底层缺氧的主要驱动力；而总氮（TN）、总磷（TP）等营养盐的富集，则会打破水体原有的生态平衡，刺激浮游植物和藻类的异常繁殖，进而引发浊度剧增与叶绿素 a 浓度的爆发。

这种耦合关系在时空维度上呈现出显著的动态非平稳性。例如，藻类光合作用会导致溶解氧在昼夜间呈现周期性波动，而降雨冲刷带来的悬浮物不仅会削弱水体透光率，抑制深层水体的光合产氧，还会携带大量吸附态磷进入河道，引发一系列连锁反应。这种跨指标的级联效应使得单一变量的波动往往是多因素共同作用的表象，单变量预测模型极易陷入“信息孤岛”，难以全面捕捉水质系统演变的全局特征。

从数据驱动建模的角度看，多变量联合建模能够充分挖掘不同水质指标在高维特征空间中的协同与制约关系。将多个强相关的水质参数作为联合输入，有助于深度学习模型学习并映射出水体状态演变的内在流形结构（Manifold Structure），从而有效滤除单一传感器监测数据中的随机噪声，显著提升模型在复杂工况下的预测稳定性与泛化精度。因此，探索并利用多变量间的耦合机制，在水质数据分析与预测中具有不可替代的理论合理性。

2.1.2 气象数据对水质的影响机理

气象因素作为驱动水环境系统演变的关键外部边界条件，从宏观尺度深刻调控着河流水质的时空分布格局。其对水质的驱动作用呈现出多尺度、多路径的复杂特征。气象驱动下的水质多变量耦合演变机理框架，如图 2-1 所示。




图 2-1 气象驱动下的水质多变量耦合演变机理框架

降水过程是打破水质原有稳态的最直接气象驱动力。一方面，强降雨通过地表径流的冲刷作用，将流域内的农业面源污染（如农田残留的氮磷化肥）、城市地表沉积物以及土壤泥沙大量输送至河道，引发著名的“初期雨水冲刷效应”，导致水体浊度、悬浮物及生源要素浓度在极短时间内呈现脉冲式激增；另一方面，对于流量较小或本底浓度较高的水体，持续性降雨又会产生显著的物理稀释作用，使得部分溶解性污染物的浓度随流量增大而反向降低。这种由降水引发的“浓缩-冲刷-稀释”机制交替出现，构成了汛期水质剧烈波动的核心原因。

气温与太阳辐射是调控水体热力学与生物化学反应的“引擎”。气温的季节与日际变化直接决定了水体的热状态。在流速较缓的河段或水库区，表层水温急剧升高易导致水体热分层，阻碍上下层水体的垂向交换，进而引发底层水体缺氧并加速底泥中内源磷的释放。同时，适宜的温度配合强烈的太阳辐射，是驱动藻类水华爆发的关键催化剂，这不仅会彻底改变水体的光学特性，还会引发 pH 和溶解氧的剧烈震荡。

风速与风向等动力学因素的影响同样不容忽视。强风能显著增加水-气界面的扰动，促进大气氧气向水体中的复氧过程；同时，在浅水区，风浪带来的底部切应力会导致底泥再悬浮，使得沉淀的污染物再次进入水体参与循环。

综上所述，气象因素对水质的影响具有高度的非线性、多模态以及显著的时间滞后效应。仅依靠水质历史序列或简单的线性回归，根本无法准确刻画外部环境突变带来的水质响应。将高精度的气象信息作为外部驱动场引入预测模型，等同于为模型提供了提前感知环境变化的“物理约束”，这正是气象数据与水质数据联合建模的理论基石，也直接印证了引入长时序再分析气象数据的必要性。

2.1.3 大气再分析理论

气象因素作为驱动水质演变的重要外部边界条件，其数据的时空连续性与物理准确性对预测模型至关重要。然而，在实际的流域水环境研究中，直接获取高密度、长

时序的真实气象站点观测数据往往面临诸多客观困境。一方面，受限于严格的数据共享壁垒与高昂的获取成本，全面且连续的实测气象资料往往难以轻易获取；另一方面，传统物理气象站点的空间分布通常较为稀疏且极不均匀，加之设备维护导致的客观缺测与数据断档现象，使得实测气象数据难以满足深度学习模型对海量、连续且无缝之时空样本的严苛要求。

鉴于上述实测数据的局限性，大气再分析技术成为了目前获取大尺度、长时序且物理机制连贯气象数据的最有效替代与补充手段。其核心原理依赖于数据同化技术，将有限的卫星遥感、地面观测、探空雷达等多源、非均匀的离散观测资料，与先进的数值天气预报模式进行动力学融合。相比于传统的单点气象站观测，再分析数据不仅克服了实测数据难以获取的壁垒，填补了监测网络在空间上的空白，更重要的是，它依托流体力学和热力学方程组，保证了生成的格点化气象变量在动力学与热力学上的物理一致性。

为了精确量化前文所述的气象对水质的驱动机理，本研究引入欧洲中期天气预报中心发布的第五代全球气候再分析数据集作为气象驱动场的物理表征。ERA5 基于集成预报系统，采用先进的四维变分同化技术生成。相比前代产品，其在时空分辨率上实现了质的飞跃（空间分辨率达 31km，时间分辨率精细至 1 小时）。

对于汉江流域而言，这种高频、高分辨率的数据特性能够精准捕捉短历时的极端气象事件（如短时强降雨、突发性气温骤变）。这对于预测由径流冲刷引起的浊度激增或总磷突变等水质响应至关重要。本研究选取 ERA5 中的总降水量、2 米气温、地表径流及风速作为关键协变量，旨在为后续的深度深度学习模型提供连续的外部约束，进而重建“大气-水文-水质”的跨圈层耦合响应机制，有效解决传统水质预测模型因缺乏环境背景场信息而导致泛化能力受限的理论痛点。

2.2 时间序列预测模型理论基础

2.2.1 循环神经网络及其变体

传统的前馈神经网络假设输入样本之间相互独立，无法有效处理具有时序依赖特征的序列数据。循环神经网络通过在隐藏层引入状态变量来实现对历史信息的“记忆”。在 t 时刻，RNN 的隐藏状态 h_t 不仅取决于当前的输入 x_t ，还依赖于上一时刻的隐藏状态 h_{t-1} ：

$$h_t = \sigma(W_{hx}x_t + W_{hh}h_{t-1} + b_h) \quad (2-1)$$

其中， W_{hx} 和 W_{hh} 为权重矩阵， b_h 为偏置项， σ 为非线性激活函数。

然而，在通过随时间反向传播算法（BPTT）进行网络训练时，标准 RNN 面临严重的梯度消失和梯度爆炸问题，难以捕捉长距离的时序依赖。为了解决这一痛点，长短期记忆网络（LSTM）和门控循环单元（GRU）相继被提出。它们通过引入复杂

的“门控机制”（如遗忘门、输入门等）来控制信息流，在一定程度上缓解了长程记忆衰退的问题。

尽管 LSTM 和 GRU 在诸多时序任务中取得了成功，但其应用于汉江流域高频水质预测时仍暴露出两大固有缺陷：第一，串行计算瓶颈。其网络结构要求 t 时刻的计算必须严格等待 $t-1$ 时刻计算完成，这导致模型无法发挥 GPU 的并行计算优势，训练效率低下；第二，超长序列记忆受限。汉江流域的逐小时水质与气象数据（如 ERA5 再分析数据）往往构成数以千计的超长序列，在处理跨月度甚至跨季节的长周期依赖时，LSTM 的记忆容量仍会面临物理瓶颈。

2.2.2 时间卷积网络

时间卷积网络（TCN）是一种专门针对序列建模的卷积神经网络架构。相比于 LSTM，TCN 在水质预测中具有并行计算快、感受野灵活可调、梯度更稳定的优势。TCN 的核心由三个技术组件构成：

（1）一维因果卷积

为了确保模型不利用未来的信息预测当前值（即避免“数据泄露”），TCN 采用因果卷积。对于时刻 t 的输出，仅依赖于 t 及其之前的输入：

$$y_t = \sum_{k=0}^{K-1} f_k \cdot x_{t-k} \quad (2-2)$$

其中 f 为滤波器， K 为卷积核大小。

（2）空洞卷积

为了在不增加参数量的情况下扩大感受野，以捕捉汉江水质的长周期（如季节性）变化，TCN 引入了膨胀系数 d 。空洞卷积公式定义为：

$$F(s) = (x *_d f)(s) = \sum_{i=0}^{k-1} f(i) \cdot x_{s-d \cdot i} \quad (2-3)$$

通过指数级增加 d （如 $d = 1, 2, 4, 8, \dots$ ），TCN 的感受野随层数呈指数级增长，从而能够“看”到很久以前的降雨或排污事件对当前水质的影响。

（3）残差连接

为了训练深层网络，TCN 引入 ResNet 中的残差块结构：

$$o = \text{Activation}(x + F(x)) \quad (2-4)$$

这保证了深层网络的信息流传输稳定性，使得构建深层 TCN 模型成为可能。

2.3 图神经网络与空间建模

现实世界中存在大量以非欧几里得空间结构呈现的数据，如交通网络、社交网络以及具有复杂拓扑连通性的空间监测网络。传统的卷积神经网络（CNN）由于依赖规则的网格结构，难以直接提取此类网络数据的空间依赖特征。为此，图神经网络被提出，旨在通过将深度学习推广至图结构数据，实现对节点属性及其复杂空间拓扑关联

的深度挖掘，为处理具有非规则空间结构的数据提供了核心理论支撑。

2.3.1 图数据的拓扑构建

图数据的处理首要步骤是将其进行严密的数学抽象。通常，一个具有复杂拓扑关系的空间网络可以被定义为图 $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$ 。

式中， $\mathcal{V}$ 表示图中节点的集合，即 $|\mathcal{V}| = N$ ，代表网络中分布的 N 个空间实体，每个节点在任意时刻 t 均附带一个多维特征向量，用以表征该实体的瞬态属性； $\mathcal{E}$ 表示边的集合，对应于连接各空间实体的物理或逻辑路径。为了数学化量化节点间的空间连通性与相互约束关系，通常需要构建邻接矩阵 $\mathbf{A} \in \mathbb{R}^{N \times N}$ 。在实际应用中，若实体间的相互影响具有明显的方向性（如顺流而下的单向物质传输或定向的信息流动），则采用有向邻接矩阵来表征该拓扑依赖。具体而言，当空间节点 j 对节点 i 存在直接的单向空间作用路径时，其对应的矩阵元素设定为非零值；反之，若无直接联系，则设定为 $A_{ij} = 0$ 。这种数学抽象将复杂的空间网络网络转化为可供深度学习模型计算的张量结构，为后续特征的空间聚合奠定了基础。

2.3.2 谱域图卷积网络原理

传统的卷积神经网络（CNN）局限于处理规则网格数据（如图像），难以直接应用于非欧几里得空间的图数据。图卷积网络（GCN）通过将卷积运算推广至图结构，实现了对节点特征及其邻域信息的有效聚合。

基于谱图理论（Spectral Graph Theory），图卷积可被定义为图信号 $\mathbf{x}$ 与滤波器 $\mathbf{g}_\theta$ 在傅里叶域的乘积。为降低计算拉普拉斯矩阵特征分解的高昂代价，提出利用切比雪夫多项式的一阶近似，推导出高效的层级传播规则：

$$\mathbf{H}^{(l+1)} = \sigma \left(\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}^{(l)} \mathbf{W}^{(l)} \right) \quad (2-5)$$

式中， $\tilde{\mathbf{A}} = \mathbf{A} + \mathbf{I}_N$ 为引入自环的邻接矩阵，意味着在特征更新时不仅考虑邻居节点，也保留节点自身的历史信息； $\tilde{\mathbf{D}}$ 为 $\tilde{\mathbf{A}}$ 的度矩阵，用于归一化以防止特征尺度爆炸； $\mathbf{H}^{(l)}$ 表示第 l 层的节点特征矩阵； $\mathbf{W}^{(l)}$ 为层间可学习的权重矩阵； $\sigma(\cdot)$ 为非线性激活函数。

在水质预测的物理语境下，该公式具有明确的机理解释：矩阵乘法运算实质上模拟了“邻域聚合”过程，即下游站点在更新当前时刻的水质状态时，会加权聚合其上游关联站点的特征信息。这在数学层面近似了污染物随水流从上游向下游的对流扩散过程。

2.3.3 图注意力网络

尽管 GCN 能够处理拓扑关系，但其标准形式通常依赖于静态的邻接矩阵，隐含假设了站点间的依赖强度恒定不变。然而，汉江流域水文条件复杂，在枯水期与丰水期，上游对下游的影响程度存在显著差异。为解决这一问题，本研究引入图注意力网

络。

GAT 通过引入自注意力机制，动态计算节点间的相互影响权重。对于节点 i 和其邻居节点 j ，其注意力系数 α_{ij} 计算如下：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\vec{a}^T [W\vec{h}_i \| W\vec{h}_j]))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(\vec{a}^T [W\vec{h}_i \| W\vec{h}_k]))} \quad (2-6)$$

式中， $\vec{a}$ 为注意力向量， $\|$ 表示向量拼接操作。该机制使得模型能够根据当前的输入特征（如暴雨强度或突发排污），自适应地调整邻接权重。例如，在暴雨径流事件中，模型可自动赋予上游节点更高的权重系数，从而更准确地捕捉污染物的高速传输特征，弥补了静态 GCN 的不足。

2.4 模型评价指标

在深度学习与时间序列预测任务中，构建科学、严密的评价指标体系是客观衡量模型拟合能力、预测精度以及泛化性能的核心环节。鉴于本研究所涉及的预测任务属于典型的连续变量回归问题，单一的评价指标往往难以全面刻画模型在不同维度的误差特征。因此，本研究引入均方根误差（RMSE）、平均绝对误差（MAE）以及决定系数（ R^2 ）等三项经典统计学指标，以构建多维度的模型效能评估体系。

2.4.1 均方根误差

均方根误差是预测值与真实值偏差的平方与观测次数比值的平方根，主要用于衡量预测结果偏离真实状态的全局离散程度。其数学表达式定义为：

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (2-7)$$

式中， N 表示测试集中的样本总序列长度； y_i 为第 i 个时间步的真实观测值； $\hat{y}_i$ 为模型在对应时间步给出的预测值。RMSE 的核心特征在于其在计算过程中对误差进行了平方运算，这意味着该指标对大误差样本具有显著的“放大”和“惩罚”效应，即对异常值或极端偏离的预测结果极其敏感。在连续环境参量的预测场景中，少数几处严重的预测失真往往会导致对系统演变状态的严重误判。因此，RMSE 能够有效评估模型在极端波动情况下的鲁棒性，该值越小，表明模型对异常波动的控制能力越强，发生严重预测偏移的概率越低。

2.4.2 平均绝对误差

平均绝对误差是所有单个观测值与预测值偏差绝对值的算术平均。其计算公式为：

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (2-8)$$

式中各项变量的物理含义与 RMSE 一致。与 RMSE 放大局部大误差的非线性特性不同, MAE 对所有样本的预测误差赋予了同等的线性权重, 能够最直观地反映预测值与真实值之间的实际平均偏离程度。由于其计算过程未涉及平方项, MAE 对极端异常值具有较好的稳健性, 能够提供一个相对平滑的全局误差评估视角。在严谨的模型评价体系中, MAE 常常需要与 RMSE 结合进行对比分析: 若 RMSE 的数值显著大于 MAE, 则深刻表明模型的预测结果中存在部分方差极大的离群误差; 若两者数值较为接近, 则说明模型的误差分布相对均匀且稳定。这种组合评估方式能够更立体地刻画模型在不同误差区间的拟合表现。

2.4.3 决定系数

上述两项指标主要从“误差损失”的逆向角度对模型进行惩罚性评估, 而决定系数 (R^2) 则从“方差解释度”的正向视角衡量模型的总体拟合优度。其数学定义为:

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (2-9)$$

式中, $\bar{y}$ 表示真实观测序列在特定时间窗口内的样本均值。公式的分子部分代表预测残差平方和, 分母部分代表真实数据的总离差平方和。决定系数 R^2 的理论取值范围通常介于 0 到 1 之间。该指标从统计学意义上量化了因变量的总变异中可由回归预测模型解释的比例。 R^2 越接近 1, 说明模型对数据全局动态变化趋势的捕捉能力越强, 预测分布与真实分布的共线性越高, 标志着模型具备卓越的规律提取能力与泛化性能。

第3章 数据集构建与预处理

3.1 研究区域与多源数据概况

本研究以数据驱动的流域水质预测为核心,围绕水质变化的时序演化特征及其受外部环境影响的复杂机理,构建了一个融合地面水质监测数据与高分辨率气象再分析数据的多源异构数据集。相较于单一数据源建模方式,多源数据融合能够从不同物理层面刻画水质变化的内在驱动机制,为后续深度学习模型的时空特征提取提供更加充分的信息基础。

3.1.1 研究区域

汉江是长江流域内规模最大、影响范围最广的一级支流之一,全长约 1577 km,发源于陕西省秦岭南麓,干流自西向东贯穿陕西南部与湖北北部地区,最终于武汉市汇入长江。汉江流域横跨我国南北气候过渡带,地形地貌类型复杂,上游以山地与丘陵为主,中游受丹江口水库控制,下游逐渐过渡为江汉平原冲积地貌,形成了典型的“山区—库区—平原”梯度水文结构。汉江流域的地形特征如图 3-1 所示。




图 3-1 汉江流域地理位置及地形分布图

从水文气候条件来看,汉江流域受东亚季风影响显著,降水在年内与年际尺度上均呈现明显的不均匀分布特征。汛期集中降雨容易引发径流突增和污染物冲刷过程,而枯水期流量降低则削弱了水体的稀释与自净能力,使得污染物浓度易出现累积效应。这种强烈的水文情势变化使流域水质演化过程具有显著的时间非平稳性特征。

在国家水资源配置格局中,汉江流域具有极其重要的战略地位。作为中国“南水北调”中线工程的核心水源区,丹江口水库承担着向华北地区跨流域调水的关键任务,

其水质安全直接关系到北京、天津及华北多省市数亿人口的饮水安全与生态安全。与此同时，随着流域内城镇化进程不断加快，工业活动和农业面源污染强度逐年上升，流域水质变化逐渐呈现出由自然因素主导向“自然—人类活动”复合驱动的转变趋势。

在上述背景下，汉江流域水质变化机理表现出显著的非线性、时序依赖性及空间异质性特征，传统基于统计假设的模型难以对其进行充分刻画。因此，选取汉江流域作为研究区域，不仅具有重要的工程实践意义，也为验证和评估时空深度学习模型在复杂流域水环境预测任务中的适用性提供了典型应用场景。

为全面捕捉汉江流域水质的时空演变规律，本文选取了流域干流上的 16 个国家级与省级地表水自动监测断面作为研究对象。这些站点在空间上呈现出显著的“上—中—下游”阶梯分布特征，涵盖了从源头山区到河口平原的多种水文地质环境（具体站点信息见表 3-1）。

表 3-1 水质检测站点信息

断面	经度	纬度	城市
烈金坝	106.2589	33.0438	汉中市
梁西渡	106.9289	33.1074	汉中市
小钢桥	108.2210	33.0361	安康市
老君关	109.0742	32.7156	安康市
羊尾	110.1478	32.8153	十堰市
陈家坡	110.9144	32.8139	十堰市
沈湾	111.6000	32.4600	襄阳市
白家湾	112.0409	32.0584	襄阳市
余家湖	112.1764	31.9142	襄阳市
转斗	112.4403	31.4661	荆门市
皇庄	112.5683	31.1964	荆门市
罗汉闸	112.6081	30.6823	荆门市
岳口	113.0694	30.5017	天门市
汉南村	113.2414	30.2351	仙桃市
小河	113.9455	30.6806	孝感市
宗关	114.2177	30.5773	武汉市

上游段（陕西段）包括烈金坝、梁西渡、小钢桥等站点，该区域地势起伏较大、水流湍急，水质主要受自然径流过程控制，人类活动影响相对较弱，水质背景值较好，可为模型提供相对稳定的对照信息。

中游段（库区及丹江口周边）涵盖羊尾、陈家坡、沈湾等关键断面，其中沈湾站位于丹江口库区核心区域。该区域水体交换过程相对缓慢，水质变化显著受水库调度及水力停留时间影响，是南水北调中线工程水质安全保障的重点区域。

下游段（江汉平原段）包括余家湖、岳口及宗关（武汉入江口）等站点。该区域人口密集、工业与农业活动强度高，支流汇入频繁，水质受城市点源污染与农业面源污染的双重胁迫，表现出高度的波动性和非线性特征，是水质预测难度最大的区域之一。

通过上述 16 个监测站点沿干流的链式布局，本文构建了覆盖汉江流域“源—汇”全过程的水质监测网络，为图神经网络（GNN）刻画上下游站点之间的空间依赖关系提供了明确的物理基础。

3.1.2 水质参数数据

水质数据来源于中国国家地表水水质自动监测实时发布平台及地方环保部门。数据采集频率为 4 小时/次，时间跨度覆盖 2021-01-01 00:00:00 至 2025-05-31 20:00:00。




图 3-2 汉南村站点水质变化

本研究选取了 9 项关键水质常规参数作为模型的输入特征与预测目标，图 3-2 以汉南村监测站点为例展示了 9 项水质参数在研究时间尺度内的变化情况。这些参数之间存在显著的生物化学耦合关系，表 3-2 详细的介绍了这些水质参数。

表 3-2 汉江流域水质参数说明

参数名称	符号	单位	环境意义与物理含义
溶解氧	DO	mg/L	反映水体中溶解氧含量，是衡量水体自净能力和生态健康状况的重要指标，受有机污染和水温变化影响显著。
高锰酸价指数	COD-MN	mg/L	表征水体中可被氧化的有机物含量，常用于反映水体有机污染程度。
氨氮	NH3-N	mg/L	主要来源于生活污水和农业径流，是评价含氮污染和富营养化风险的重要指标。

表 3-2 汉江流域水质参数说明（续）

参数名称	符号	单位	环境意义与物理含义
总氮	TN	mg/L	表征水体中所有形态氮的总量，与水体富营养化过程密切相关。
总磷	TP	mg/L	反映水体中磷污染水平，是藻类生长和水体富营养化的重要限制因子。
酸碱值	PH	-	表征水体酸碱性，对水生生物生存及化学反应过程具有重要影响。
水温	WT	℃	影响溶解氧溶解度、化学反应速率及微生物代谢活动，是水质变化的重要调节因素。
浊度	TURB	NTU	反映水体中悬浮颗粒物含量，与径流冲刷和面源污染过程密切相关。
电导率	EC	μS/cm	表征水体中溶解性离子浓度，常用于反映水体矿化度和综合污染状况。

原始水质数据属于典型的非欧几里得结构数据，且由于设备维护等原因，存在不同程度的缺失值与异常值，后续章节将详细介绍针对性的预处理策略。

3.1.3 气象驱动数据

水质变化并非孤立过程，其深受气象水文条件的影响。例如，强降雨会引发地表径流，将地表的污染物冲刷入河（面源污染效应），导致浊度和污染物浓度短时升高；而枯水期流量减少则可能导致污染物稀释能力下降。

鉴于地面气象站点分布稀疏且容易缺测，本研究引入了欧洲中期天气预报中心发布的 ERA5 再分析数据作为外部驱动变量。ERA5 是目前全球公认的最先进的第五代大气再分析数据集，具有全覆盖、无缺失、长时序的优势。本研究选取了以下关键气象特征与水质数据进行时空对齐：

表 3-3 ERA5 气象驱动变量及其含义说明

变量名称	特征名	单位	物理含义与作用
总降水量	precipitation	mm	表征降雨强度，是触发地表径流和面源污染冲刷过程的直接驱动因子
地表径流	surface_runoff	mm	模拟降雨产生的水流汇入量，有助于模型理解流量变化对污染物浓度稀释或富集的影响
2 m 气温	air_temp_2m	℃	反映季节性变化特征，影响水温及水体中化学反应和生物过程
10 m 风速	wind_speed_10m	m/s	影响水体表层扰动与空气—水界面交换过程，间接作用于溶解氧变化

原始 ERA5 数据为格点数据，空间分辨率为 $0.25^{\circ} \times 0.25^{\circ}$ 。为了将其与离散的水质站点融合，本研究采用了双线性插值算法，提取各监测断面经纬度对应的精确气象强迫项，从而构建了“水质-气象”双流驱动数据集。

3.2 数据预处理

3.2.1 缺失值处理

在实际的水质自动监测过程中，受传感器故障、网络传输丢包、设备例行检修或断电等不可控因素影响，原始监测数据不可避免地存在不同程度的缺失现象。缺失值的存在不仅破坏了时间序列的连续性，还会导致深度学习模型输入维度的错位，进而降低预测精度。

不同水质参数受环境交互机制的影响，在时间尺度上表现出显著的差异性。以宗关站点为例，图 3-3 展示了部分典型水质参数的原始时间序列变化特征。可以看出，水温（WT）、PH 等物理指标变化平缓，具有较强的自相关性；而氨氮（NH₃-N）、浊度（Turbidity）等污染物指标则波动剧烈，呈现出明显的非平稳性。若忽略参数的物理特性差异，采用单一的插值方法进行“一刀切”式填补，极易引入不合理的噪声或虚假趋势。因此，本研究采用一种基于参数时变特性的分层差异化填补策略。




图 3-3 宗关站点部分水质参数变化

针对汉江流域水质数据的多源异构特性，本研究将 9 类水质参数划分为三种模式，并分别设计填补算法：

（1）平稳连续型参数（水温、pH、电导率）： 此类参数受自然环境（如光照、地质背景）的惯性影响较大，短时波动小，时间连续性强。针对此类数据，本研究采用线性插值法。该方法利用缺失点前后的已知观测值构建线性函数，能够较好地还原物理指标在短时间内的平滑演变趋势，保持数据的局部特征。

（2）突变波动型参数（氨氮、总磷、浊度）： 此类参数通常受降雨径流、排污事件等外部强迫影响，具有显著的突发性。针对此类数据，采取长短时分类处理。对于短时缺失，定义为连续缺失时间 ≤ 24 小时（即连续缺失数据点数量 ≤ 6 个）的区间。对于短时缺失，认为水环境系统具备一定的物理惯性，水质状态未发生根本性跃迁，因此仍采用线性插值以维持序列的局部完整性。长时缺失：定义为连续缺失时间 $>$

24 小时（即连续缺失数据点数量 > 6 个）的区间。对于长时缺失，由于经历的时间跨度较长，简单的线性连线会无视期间可能发生的降雨或排污事件，从而产生错误的长期趋势并误导预测模型。因此，采用基于历史统计特征的均值填补法，即利用该站点相同时段的历史均值或邻近滑动窗口的统计均值进行填充，以有效避免对异常波动的过度平滑或虚构趋势。

（3）复合驱动型参数（溶解氧、高锰酸盐指数）：此类参数的变化机制复杂，既受水温等物理条件制约，又与有机污染负荷密切相关。本研究在保证序列稳定性的前提下，采用线性插值与统计均值填补相结合的混合策略，以最大程度保留数据的统计分布特性。

基于上述策略，本研究完成了对汉江流域各站点缺失数据的重构。图 3-4 展示了宗关站点经预处理后的水质参数时间序列。图中红色曲线段明确标识了由算法生成的填补数据，其余颜色为原始观测数据。可以看出，填补后的数据不仅在数值上保持了时间序列的完整性，更在趋势上有效拟合了不同参数的周期性波动与突变特征（如溶解氧的昼夜节律及氨氮的峰值衰减），消除了原始数据断裂导致的特征丢失问题，为后续构建时空预测模型提供了高质量的数据基础。




图 3-4 缺失值处理后的水质参数变化

3.2.2 异常值检测

水质自动监测系统处于复杂的野外环境中，受传感器探头生物附着、水体杂质干扰、电压波动及信号传输误码等因素影响，原始数据中常夹杂着偏离物理真实范围的离群点。这些异常值通常表现为极短时间内的数值突变或超出量程的非逻辑值（如 $\text{pH} < 0$ 或 $\text{DO} > 20 \text{ mg/L}$ ）。若不加以剔除，这些噪声将严重干扰神经网络对正常时

空特征的学习，导致模型梯度爆炸或预测结果失真。

传统的 3σ 准则假设数据严格服从正态分布。然而，汉江流域的氨氮、总磷等污染物浓度数据往往呈右偏分布，且存在季节性波动。在这种非正态分布下， 3σ 准则极易造成漏检或误判。因此，本研究采用箱线图法进行异常值识别。该方法基于数据的四分位距，对数据分布形态不作特定假设，具有较强的稳健性。具体的检测步骤如下：

(1) 统计量计算：对某一监测断面 i 的某种水质参数序列 X ，计算其第一四分位数 Q_1 (25% 分位数) 和第三四分位数 Q_3 (75% 分位数)。

(2) 四分位距定义：计算反映数据集中趋势的四分位距 $IQR = Q_3 - Q_1$ 。

(3) 阈值设定：构建异常检测的上下限截断阈值：

$$\text{Lower} = Q_1 - 1.5 \times IQR \quad (3-1)$$

$$\text{Upper} = Q_3 + 1.5 \times IQR \quad (3-2)$$

(4) 清洗策略：遍历时间序列，判定满足 $x_t < \text{Lower}$ 或 $x_t > \text{Upper}$ 的数据点为统计学异常值。同时，结合物理极值约束（如水温不能低于 -5°C ），将识别出的异常点置为 NaN（空值），并纳入上一节所述的缺失值填补流程进行修正。

图 3-5 展示了箱线图法检测异常值的统计学原理及在实际氨氮数据清洗中的应用效果。




图 3-5 氨氮 $\text{NH}_3\text{-N}$ 异常值检测

3.2.3 数据归一化

汉江流域水质监测数据属于典型的多维异构时间序列，各特征之间存在显著的量纲与数量级差异。例如，电导率 (EC) 的数值范围通常在 $200 \sim 600 \mu\text{S}/\text{cm}$ 之间，而总磷 (TP) 的浓度往往仅为 $0.02 \sim 0.2 \text{ mg/L}$ 。两者数值差异高达 3 到 4 个数量级。

若直接将原始数据输入深度学习模型，在反向传播过程中，数值较大的特征（如电导率）将主导损失函数的梯度更新方向，导致模型对小数值特征（如总磷、氨氮）

不敏感。从几何角度看,这种量纲差异会导致损失函数的等高线呈现狭长的椭球体形状,使得梯度下降路径呈“之”字形震荡,极大地降低了模型的收敛速度,甚至导致训练发散。

为了消除量纲影响,构建各向同性的特征空间,本研究采用 Z-Score 标准化方法对输入数据进行线性变换。该方法假设原始特征服从正态分布,将其映射为均值为 0、标准差为 1 的标准正态分布。设某水质特征序列为 $X = \{x_1, x_2, \dots, x_T\}$, 其标准化计算公式如下:

$$x'_t = \frac{x_t - \mu}{\sigma} \quad (3-3)$$

其中, x'_t 为标准化后的数值, μ 和 σ 分别为该特征在训练集上的均值与标准差

3.3 气象数据时空对齐

本研究涉及的数据集包含两类显著异构的数据源:一是基于离散地理坐标的地面水质监测站点数据,二是基于规则经纬度网格的 ERA5 气象再分析数据。两者在空间分布形态和时间采样频率上均存在不匹配问题。为了构建统一的输入张量供深度学习模型训练,必须在时空维度上对多源数据进行严格的对齐与融合。

3.3.1 空间对齐

水质监测数据来自汉江流域的 16 个具体断面,具有唯一的经纬度坐标。而 ERA5 气象数据是覆盖全球的栅格化产品,其空间分辨率为 $0.25^\circ \times 0.25^\circ$ (约为 $27\text{k} \times 27\text{k}\text{m}$)。若直接采用最近邻法,即直接选取距离站点最近的网格点数据作为站点气象特征,会引入阶梯状误差,忽略了气象场在空间上的连续变化梯度。为了更精确地捕捉站点局部的微气象特征,本研究采用双线性插值法实现从格点到站点的空间映射。

假设某一水质监测站点 P 的坐标为 (x, y) , 其落在 ERA5 网格的四个邻近格点 $Q_{11} = (x_1, y_1), Q_{12} = (x_1, y_2), Q_{21} = (x_2, y_1), Q_{22} = (x_2, y_2)$ 所围成的矩形区域内。其中 Q_{ij} 对应的气象属性值(如降雨量)记为 $f(Q_{ij})$ 。双线性插值通过在 X 轴和 Y 轴方向分别进行两次线性插值来估算点 P 的值。首先在 X 轴方向上进行线性插值,得到辅助点 R_1, R_2 的值。随后,在 Y 轴方向上对 R_1, R_2 进行插值,得到站点 P 的最终估计值 $f(P)$ 。

$$\begin{cases} f(R_1) \approx \frac{x_2 - x}{x_2 - x_1} f(Q_{11}) + \frac{x - x_1}{x_2 - x_1} f(Q_{21}) \\ f(R_2) \approx \frac{x_2 - x}{x_2 - x_1} f(Q_{12}) + \frac{x - x_1}{x_2 - x_1} f(Q_{22}) \end{cases} \quad (3-4)$$

$$f(P) \approx \frac{y_2 - y}{y_2 - y_1} f(R_1) + \frac{y - y_1}{y_2 - y_1} f(R_2) \quad (3-5)$$

通过上述计算,本研究将 16 个离散站点的气象特征精确映射为连续的物理场,

有效避免了空间离散化带来的边界效应。

3.3.2 时间对齐

原始 ERA5 数据的采样频率为 1 小时/次, 而经预处理后的水质监测数据频率为 4 小时/次。为了使气象驱动变量与水质响应变量在时间步上一一对应, 需要对 ERA5 数据进行降采样或聚合处理。

针对不同物理属性的气象参数, 本研究采取差异化的对齐方案: 瞬时状态量(如气温、气压):

(1) 采用临近匹配法。选取与水质监测时刻(如 00:00, 04:00, ...)时间戳完全一致的 ERA5 瞬时值作为输入。

(2) 累积通量(如总降水量、地表径流): 采用窗口聚合法。考虑到降雨对水质的影响具有滞后性和累积效应, 对于 t 时刻的水质样本, 计算其过去 4 小时窗口 $[t - 3, t]$ 内的 ERA5 降雨量总和作为该时段的驱动特征。

第4章 基于动态时空图卷积的水质预测模型

本章研究的核心任务是利用已有的多站点水质监测数据及同期 ERA5 气象数据，挖掘其中潜在的时空依赖关系，对流域内各站点未来的水质状况进行精准预测。定义汉江流域内包含 N 个水质监测站点，每个站点监测 C 种水质参数。记 t 时刻的水质特征矩阵为 $X_t \in \mathbb{R}^{N \times C}$ 。同时，引入经过空间对齐的 ERA5 气象驱动数据（包含降雨、气温等），记 t 时刻的气象特征矩阵为 $M_t \in \mathbb{R}^{N \times D}$ ，其中 D 为气象特征维度。流域水质预测问题可定义为：给定历史时间窗口 T_{in} 内的水质序列 $\mathcal{X} = \{X_{t-T_{in}+1}, \dots, X_t\}$ 和气象序列 $\mathcal{M} = \{M_{t-T_{in}+1}, \dots, M_t\}$ ，构建预测模型 $F(\cdot)$ ，预测未来 T_{out} 个时间步的水质变化 $\hat{Y}$ ，其形式化表达如(4-1)：

$$\hat{Y} = \{\hat{X}_{t+1}, \dots, \hat{X}_{t+T_{out}}\} = F(\mathcal{X}, \mathcal{M}; \Theta) \quad (4-1)$$

其中， Θ 代表预测模型中所有可学习参数集合，涵盖了后续模块中的卷积核权重、注意力参数及全连接层参数等。

区别于常规的时间序列预测，多站点水质时空演化是一个受多重水文物理过程交织影响的复杂系统。其核心建模难点在于：空间上，站点间的污染输移与水力联系会随外部气象条件发生剧烈变化；时间上，水质自身的状态演变与气象驱动量的脉冲变化呈现出显著的异质性特征。

针对上述痛点，本章设计了一种基于气象感知的动态图卷积网络水质预测模型（MD-DySTGCN, Meteorology-Driven Dynamic Spatial-Temporal Graph Convolutional Network）。为了直观展示模型处理多源异构数据的机制与整体计算流向，图 4-1 给出了该模型的总体架构。




图 4-1 基于动态时空图卷积的水质预测模型结构图

模型的前向传播过程自上而下可划分为三个递进的核心阶段：

第一阶段（多源数据输入）：流域历史水质观测序列与气象驱动序列作为独立的数据流并行输入网络。

第二阶段（特征解耦与动态构图）：一方面，通过参数独立的双塔网络分别提取水质与气象的时序依赖特征；另一方面，利用气象序列动态推演并生成刻画当前真实水动力演变的邻接矩阵。

第三阶段（物理感知时空融合与多步预测）：依托生成的动态图结构，执行多层图卷积以实现空间信息的隐式输移，并利用物理门控机制自适应调节气象脉冲对水质的冲击权重，最终经过解码层输出未来多步的水质演化预测结果。

通过上述自底向上的模块设计，本模型能够在统一的网络框架下实现时空特征的深度解耦与物理协同。下文将分别对网络中各核心模块的构建动机与具体数学表达展开详细阐述。

4.1 气象驱动的动态邻接矩阵生成机制

在流域水质预测任务中，站点之间的空间依赖关系是决定预测精度的关键因素之一。图神经网络通过邻接矩阵对空间拓扑结构进行建模，使得模型能够在空间维度上实现信息传播与特征聚合。因此，邻接矩阵的构建方式在很大程度上决定了模型对真实水文过程的刻画能力。

现有研究通常基于地理距离衰减函数或静态河网拓扑关系构建邻接矩阵，这类方法在一定程度上能够反映站点之间的空间接近性或水力连通性。然而，其核心假设是：站点间的影响关系在时间维度上保持不变。对于水文条件相对稳定或人工调控较强的流域，该假设尚具合理性；但对于水文过程受气象驱动显著、丰枯水期差异明显的汉江流域而言，该假设往往难以成立。

降雨过程的突发性和不均匀性，会在短时间尺度内显著改变地表产流强度与河道汇流条件，从而导致污染物在空间上的输移路径和传播速度发生剧烈变化。若仍采用静态邻接矩阵，将难以反映这种空间依赖关系的时变特征，进而限制模型的预测上限。

因此，本文设计一种基于气象驱动的动态邻接矩阵生成机制，以增强模型对流域真实水动力过程的动态捕捉能力。该机制的整体计算架构如图 4-2 所示，其核心流程可解耦为三个递进的模块：首先，通过节点状态嵌入网络提取气象特征 $\mathbf{M}_t$ 的高维时变表征；其次，基于自注意力机制计算站点间的动态相似度得分，生成未约束的邻接权重；最后，引入基于真实河网拓扑的物理掩码 $\mathbf{A}_{\text{mask}}$ 进行稀疏化与规范化，最终输出兼具数据驱动灵活性与物理规律严谨性的动态邻接矩阵 $\mathbf{A}_t$ 。




图 4-2 气象驱动的动态邻接矩阵生成模块结构图

4.1.1 动态构图的物理动机

从水动力学角度来看，河道中溶解性或颗粒态污染物的输移过程通常可由一维对流 - 扩散方程进行描述。其基本形式如下：

$$\frac{\partial C}{\partial t} + v \frac{\partial C}{\partial x} = D_x \frac{\partial^2 C}{\partial x^2} \quad (4-2)$$

其中， C 为河道断面处的污染物浓度， t 为时间， x 为沿河道纵向的空间距离， v 为河道平均流速， D_x 为纵向扩散系数。该方程表明，污染物在空间上的迁移不仅与其初始浓度分布有关，还受到河道流速、扩散系数等水动力参数的共同影响。

该方程表明，污染物在空间上的迁移不仅与其初始浓度分布有关，还受到河道流速、扩散系数等水动力参数的共同影响。上游污染物输移至下游断面的时间滞后 t_{lag} 与河道平均流速 v 呈显著反比关系，而扩散影响范围则与纵向扩散系数 D_x 密切相关。值得注意的是，这些水动力参数并非静态常数，而是直接受降雨补给、地表径流以及汇流过程的控制。

在丰水期或强降雨事件发生期间，流域内地表产流增强，河道流量迅速上升，导致流速显著加快。在此情形下，上游站点的污染物能够在较短时间内输移至下游站点，且冲刷效应增强，使得上游对下游水质变化的影响强度明显提升。此时，空间图结构应体现为高权重、强耦合的特征。

相反，在枯水期或长期无雨条件下，河道流量较小，流速减缓，污染物在河道中滞留时间增加，上游对下游的影响逐渐减弱，部分站点之间的空间关联甚至趋于消失。此时，空间图结构应体现为低权重、弱连接的特征。

上述分析表明，站点间的空间依赖关系具有明显的时间非平稳性。若采用静态邻接矩阵，将无法反映丰枯水期空间关系的动态演化过程。因此，有必要引入能够随气象条件变化而动态调整的构图机制。

4.1.2 气象驱动的点状态嵌入建模

为在数据层面刻画气象条件对空间关系的调制作用，本文引入 ERA5 气象数据作为动态图构建的外部驱动信息。设在时刻 t ，流域内所有站点对应的气象特征矩阵为 $M_t \in \mathbb{R}^{N \times D}$ ，其中 N 表示站点数量， D 为气象特征维度，各气象变量已通过空间插

值与站点位置对齐，并进行归一化处理。由于气象特征与空间依赖关系之间往往呈现复杂的非线性映射关系，本文采用节点嵌入网络对气象特征进行高维表示学习，形式化表达如(4-3)：

$$\mathbf{E}_t = \phi(\mathbf{M}_t \mathbf{W}_E + \mathbf{b}_E) \quad (4-3)$$

其中， $\mathbf{W}_E \in \mathbb{R}^{D \times d_E}$ 为可学习参数矩阵， $d_E \in \mathbb{R}^{d_E}$ 为嵌入空间纬度， $\phi(\cdot)$ 表示 ReLU 激活函数。通过该映射过程，原始气象变量被投影至统一的潜在空间，得到的 $\mathbf{E}_t \in \mathbb{R}^{N \times d_E}$ 可视作各站点在当前气象条件下的综合水文状态表征，为后续空间相关性建模提供基础。

4.1.3 基于自注意力的动态邻接权重生成

在获得节点气象状态嵌入 $\mathbf{E}_t$ 后，本文借鉴自注意力机制的思想，通过计算站点间嵌入向量的相似度来刻画其空间关联强度。对于任意站点 i 和 j ，其在 t 时刻的相关性得分 $S_{ij,t}$ 定义为(4-4)：

$$S_{ij,t} = \frac{\mathbf{E}_{i,t}(\mathbf{E}_{j,t})^T}{\sqrt{d_E}} \quad (4-4)$$

其中， $\mathbf{E}_{i,t}, \mathbf{E}_{j,t} \in \mathbb{R}^{d_E}$ 分别表示嵌入矩阵 $\mathbf{E}_t$ 中站点 i 和 j 对应的特征向量； $\sqrt{d_E}$ 为缩放因子，用于防止点积数值过大导致网络训练过程中的梯度不稳定。该缩放点积操作有效地衡量了不同站点在当前气象条件下的潜在特征相似性。

为进一步增强模型的表达能力，本文在相似度得分的基础上引入多层感知机 (MLP) 进行非线性特征变换，形式化表达如下：

$$\mathbf{A}'_{ij,t} = \text{ReLU}(\text{MLP}(S_{ij,t})) \quad (4-5)$$

由此构建得到未约束的动态邻接矩阵 $\mathbf{A}'_t \in \mathbb{R}^{N \times N}$ ，该矩阵能够根据气象条件的动态演变，自适应地调整流域内各站点间的空间连接权重与影响强度。

4.1.4 物理先验约束与邻接矩阵规范化

尽管上述方法能够从数据层面刻画空间依赖关系，但完全数据驱动的构图方式可能引入违背水文物理规律的虚假连接。为此，本文引入基于河网拓扑的物理先验约束，对动态邻接矩阵进行筛选与稀疏化。通过构建静态物理掩码矩阵 $\mathbf{A}_{\text{mask}} \in \{0,1\}^{N \times N}$ ，当站点 i 位于站点 j 的上游且二者之间存在直接水力联系时，令 $\mathbf{A}_{\text{mask},ij} = 1$ ，否则为 0。随后，将其与动态权重矩阵 $\mathbf{A}'_{ij,t}$ 进行哈达玛积 $\tilde{\mathbf{A}}_{ij,t} = \mathbf{A}'_{ij,t} \cdot \mathbf{A}_{\text{mask},ij}$ ，得到物理约束下的掩码矩阵 $\tilde{\mathbf{A}}_{ij,t}$ 。然后对邻接矩阵进行行归一化处理，以保证数值稳定性并便于后续图卷积计算。为避免无水力联系的站点在归一化过程中被重新分配权重，归一化操作仅在有效邻居节点间进行：

$$\mathbf{A}_{ij,t} = \frac{\exp(\tilde{\mathbf{A}}_{ij,t})}{\sum_{k=1}^N \exp \tilde{\mathbf{A}}_{ik,t}} \quad (4-6)$$

通过上述步骤，本文构建得到随时间变化的动态邻接矩阵序列 $\mathbf{A} = \{\mathbf{A}_{t-T_m+1}, \dots, \mathbf{A}_t\}$ 。

该动态空间结构能够在不同水文情势下自适应调整站点间的空间耦合强度，为后续动态图卷积操作提供物理一致的空间先验。

4.2 基于双塔 TCN 的时序特征提取

流域水质演化过程不仅受到瞬时气象条件的影响，还表现出显著的时间依赖特征，例如季节性变化、累积效应以及丰枯水期交替等现象。这种时间依赖通常具有跨度长、尺度多样的特点，属于典型的长序列时序建模问题。

传统的循环神经网络（RNN）及其变体（如 LSTM、GRU）虽然能够在一定程度上捕捉时间依赖关系，但在处理长时间序列时仍面临梯度消失、训练效率低以及难以并行计算等问题。与此同时，近年来备受瞩目的基于自注意力机制的 Transformer 架构虽然具备强大的长序列建模能力，但在流域水质演化这一特定物理场景中同样存在局限。一方面，标准 Transformer 的注意力机制计算复杂度随序列长度呈平方级增长，在处理长历史观测窗口时计算开销巨大，且其缺乏局部归纳偏置，在流域站点样本量有限的情况下极易发生过拟合；另一方面，全局自注意力机制倾向于关注全局依赖，容易平滑掉由局部降雨或突发排污引起的短期高频脉冲信号，从而弱化了模型对水质关键突变特征的刻画

针对上述不足，本文引入时间卷积网络（TCN）作为核心的时序特征提取模块，并在此基础上设计了双塔结构，以分别建模水质状态变量与气象驱动变量的时间演化特征。

4.2.1 TCN 结构配置与参数设置

时间卷积网络（TCN）的基本理论与模型结构已在第2章中进行了系统介绍，本节不再对其通用原理展开重复论述，而是重点分析 TCN 在流域水质时序建模任务中的适用性，并说明其在本文模型中的具体结构配置。

流域水质变化过程通常具有显著的多尺度时间依赖特征。一方面，水质指标在短时间尺度上会受到降雨事件、突发排污等因素的影响，表现出明显的脉冲式变化；另一方面，在较长时间尺度上，又呈现出季节性波动和趋势性演化特征。这种长短期依赖并存的特性，对时序建模方法的感受野和建模能力提出了较高要求。

相比于循环神经网络类模型，TCN 通过空洞卷积机制能够在较浅网络结构下获得较大的时间感受野，从而有效捕捉长期依赖关系。同时，其基于卷积的结构具备良好的并行计算能力，适合处理多站点、多变量的流域水质时序数据。

结合汉江流域水质数据的采样频率与水文过程特征，本文在 TCN 结构设计中采用指数增长的膨胀系数配置策略。设第 1 层卷积的膨胀因子为 2^1 。若 TCN 网络深度为 L ，卷积核大小为 K ，则其理论最大感受野为：

$$R=1+(K-1)(2^L-1) \quad (4-7)$$

在本文实验设置中,取 $K=3, L=4$,使得模型在单个站点上能够覆盖约 30 个历史时间步,从而捕捉一次典型降雨-径流事件对水质变化的持续影响。该感受野长度在实验中验证能够在建模精度与计算复杂度之间取得良好平衡。

通过上述配置,TCN 能够在保证因果性的前提下,高效提取流域水质与气象驱动序列中的关键时间特征,为后续的空间建模与特征融合奠定基础。

4.2.2 残差结构与正则化策略

为了缓解深层网络训练过程中的梯度消失问题并提升模型的收敛稳定性,本文在 TCN 模块内部引入了残差连接机制。对于网络中的第 1 个残差块,其特征输出可表示为:

$$o = \sigma(x + \mathcal{F}(x)) \quad (4-8)$$

其中 x 表示残差块输入, $\mathcal{F}(\cdot)$ 表示由两层“空洞因果卷积+非线性激活”构成的变换分支, $\sigma(\cdot)$ 为最终的非线性激活函数。当输入特征与输出通道数不一致时,采用 1×1 卷积进行线性,以保证残差相加操作的可行性。

4.2.3 双塔 TCN 结构设计

考虑到流域水质预测任务中所涉及变量的异质性特征,水质变量与气象变量在物理含义、数值分布以及时间变化模式上均存在显著差异。水质指标通常表现为状态量,其变化过程具有较强的自相关性和惯性特征;而气象变量则更多体现为外部驱动量,往往呈现出突发性强、时间分布不均匀等特点。若在输入阶段直接对二者进行拼接并采用统一的时间编码器,容易导致不同类型特征在时序建模过程中相互干扰,从而削弱模型对关键时间模式的刻画能力。

基于上述考虑,本文引入双塔时间卷积结构,通过构建两个参数独立但结构相同的时间编码器,分别对水质序列与气象驱动序列进行建模,以实现不同类型时间依赖特征的解耦提取。

(1) 水质塔

水质塔的输入为历史时间窗口内的水质观测序列 $\mathcal{X} \in \mathbb{R}^{T_{in} \times C}$,该序列经由多层残差 TCN 模块进行特征提取,输出水质时间特征表示:

$$H_{water} \in \mathbb{R}^{T_{in} \times F} \quad (4-9)$$

其中 T_{in} 表示输入历史时间步长, C 为水质指标特征维度, F 表示提取出来的隐藏层时间特征维度。水质塔主要关注水质指标在时间维度上的内在演化规律,其提取的特征能够有效刻画水质变量的自相关性、周期性变化以及长期趋势特征。例如,在枯水期或气象条件相对稳定的阶段,水质变化往往以缓慢演化为主,该特征主要由水质塔进行建模。

(2) 气象塔

气象塔的输入为与水质序列时间对齐的历史气象驱动序列 $\mathcal{M} \in \mathbb{R}^{T_{in} \times D}$,其中其中 D 表示气象特征维度。气象塔采用与水质塔相同的 TCN 结构配置,但网络参数

相互独立,以保证两类特征在时间建模阶段的充分解耦。经过多层残差 TCN 模块后,得到气象时间特征表示:

$$\mathbf{H}_{\text{meteo}} \in \mathbb{R}^{T_{\text{in}} \times F} \quad (4-10)$$

该特征主要编码降雨脉冲、气温变化等外部驱动对流域系统的时间影响模式。双塔结构在保持时间维度一致的同时,实现了对不同类型变量的解耦建模,为后续空间建模与特征融合提供了对齐的高维时间表示。为了直观展示上述异质变量的时间特征解耦提取过程,本文绘制了双塔 TCN 模块的整体架构与内部详细结构,如图 4-3 所示。




图 4-3 双塔 TCN 与残差模块结构图

模型在时间维度上采用了平行且解耦的双塔架构。上方分支为水质塔,接收历史水质观测序列作为输入;下方分支为气象塔,接收气象驱动序列作为输入。两个分支均由 L 层堆叠的残差 TCN 模块构成。由于两塔的参数相互独立,模型能够有效避免不同物理量在时间编码阶段的特征混淆,最终分别输出在时间维度严格对齐的高维特征表示 $\mathbf{H}_{\text{water}}$ 与 $\mathbf{H}_{\text{meteo}}$ 。

此外,图 4-3 下半部分进一步展开了单个残差 TCN 模块的内部计算流向。为有效提取长序列的时序依赖并缓解深层网络的梯度消失问题,模块内的输入特征分别进入两个分支:主分支依次经过空洞因果卷积与 ReLU 非线性激活函数,以指数级扩大时间感受野并提取局部时序模式;残差分支则通过 1×1 卷积进行线性投影,以保证通道维度的对齐。最终,两分支的特征张量通过逐元素相加操作进行融合,输出至下一网络层。这种双塔结合残差卷积的设计,既保证了多尺度时序信息的有效传递,又实现了对流域异质驱动因素的深度解耦建模。

4.3 动态图卷积与物理感知融合

通过前述双塔 TCN 模块,本文已分别从水质状态变量与气象驱动变量两个角度,提取了各站点在时间维度上的高维特征表示。然而,该阶段的建模过程仍然局限于单站点内部的时间依赖关系,尚未显式刻画流域内不同站点之间的空间交互作用。

在流域尺度上,水质演化过程本质上是一个典型的时空耦合系统。污染物在河道中的输移不仅受到局部水质历史状态的影响,还受到上游来水、水动力条件以及气象过程的共同调制。因此,有必要在时间特征提取的基础上,引入空间建模机制,对站点之间的相互影响关系进行联合建模。

基于上述考虑,本文在本节中引入动态图卷积网络,并结合物理感知的特征融合机制,实现时间特征与空间结构的深度耦合。该部分的核心计算流向与模块架构如图 4-4 所示。




图 4-4 动态图卷积与物理感知融合模块结构图

4.3.1 多层动态图卷积

在流域水污染演变过程中,单一站点的水质状态不仅是历史时序的延续,更是整个河网空间水动力交互的局部缩影。为精准捕捉站点间的空间交互与污染物输移规律,本模型在双塔 TCN 提取出时间特征 (H_{water} 与 H_{meteo}) 的基础上,利用 4.1 节生成的动态邻接矩阵 A_t 执行图卷积操作。

与传统基于距离或固定拓扑的静态图卷积网络 (GCN) 不同,本模型在每一个时间步 t 都基于当前演变的水动力状态执行空间聚合,形成空间结构动态变化的卷积过程。在第 1 层动态图卷积中,节点特征的更新过程形式化定义为:

$$Z_t^{(l+1)} = \sigma \left(\tilde{D}_t^{-\frac{1}{2}} A_t \tilde{D}_t^{-\frac{1}{2}} Z_t^{(l)} \Theta^{(l)} \right) \quad (4-11)$$

其中, $Z_t^{(l)}$ 为第 l 层的隐藏层节点特征,对于初始层 ($l=0$),其输入分别为经过时间维编码的 H_{water} 或 H_{meteo} ; D_t 为动态邻接矩阵 A_t 的度矩阵,用于对图结构进行对称归一化处理 ($\tilde{D}_t^{-\frac{1}{2}} A_t \tilde{D}_t^{-\frac{1}{2}}$),以消除度数较大的节点在特征传播过程中造成的

数值量级偏移； $\Theta^{(l)}$ 为当前卷积层中可学习的权重参数矩阵； $\sigma(\cdot)$ 为非线性激活函数（如 ReLU）。

这一动态卷积过程本质上蕴含了图注意力的思想。由于 A_t 是由气象特征动态驱动生成的，公式中的归一化邻接矩阵不再是简单的连通性标识，而是代表了在当前时刻 t 的气象条件下，上游各站点对下游站点的“注意力分配权重”或“污染贡献度”。这种机制使得模型能够在丰水期自动放大上游节点的传播权重，而在枯水期则相对强化节点自身的局部特征。

在具体的传播机制上，为了刻画污染物在复杂河网中长距离、跨断面的输移过程，模型通过堆叠 L_g 层动态图卷积，在空间维度上逐步聚合来自多跳邻域的信息。单层图卷积仅能捕获一阶直接相邻站点的影响，而随着网络深度的增加，每个站点的空间感受野呈指数级扩大。从水文学角度来看，这种多层传播在数学上完美模拟了污染物在河网中的“逐级隐式输移”过程：

（1）拓扑约束保障物理真实性：由于基础矩阵 A_t 已通过河网物理掩码矩阵（Mask）进行了严格的正向水力约束，特征在图网络中的传播被严格限制在由上游向下游的真实路径中，彻底避免了深度学习模型在处理复杂图结构时容易产生的违背物理常识的逆向传播或跨支流虚假污染干扰。

（2）时空特征的并行解耦提取：上述动态图卷积操作被平行应用于水质时间特征与气象时间特征，从而分别获得了融合动态空间拓扑信息的水质时空特征表示 $Z_{water,t}^{sp}$ 与气象时空特征表示 $Z_{meteo,t}^{sp}$ ，为后续的物理门控融合奠定了对齐的特征基础。

通过这种将动态空间拓扑与多跳聚合相结合的设计，模型在避免原始观测数据层面直接传播导致噪声放大的同时，赋予了神经网络随实时水文条件自适应调整空间感受野的强大表达能力。

4.3.2 物理感知门控机制的水文解释

在获得水质与气象的空间特征表示为 $Z_{water,t}^{sp}$ 和 $Z_{meteo,t}^{sp}$ ，考虑到气象驱动对水质变化的影响往往呈现高度的非线性，本文摒弃了常规的特征直接拼接或简单线性加权方法，创新性地引入了物理感知的门控融合机制，其门控系数 λ_t 的形式化定义如下：

$$\lambda_t = \text{Sigmoid}(W_g[Z_{water,t}^{sp} \parallel Z_{meteo,t}^{sp}] + b_g) \quad (4-12)$$

其中， $\parallel$ 表示特征在通道维度的拼接操作， W_g 和 b_g 分别为可学习的权重矩阵与偏置项， $\text{Sigmoid}(\cdot)$ 激活函数将输出严格映射至 $(0,1)$ 区间，使其具备“调节阀”的数学属性。

在获取动态门控系数 λ_t 后，时空综合特征 $H_{final,t}$ 的融合过程通过自适应加权表示为：

$$H_{final,t} = \lambda_t \odot Z_{meteo,t}^{sp} + (1 - \lambda_t) \odot Z_{water,t}^{sp} \quad (4-13)$$

其中, $\odot$ 为哈达玛积, 即逐元素相乘。

该门控机制的核心物理意义在于精准模拟真实水文系统中的“非线性阈值效应”。在实际流域演变中, 并非所有的气象波动都会立刻引发水质的剧烈恶化。例如, 在降雨初期或小规模降雨情境下, 水分往往被流域土壤吸收或用于填洼, 未能形成有效的地表径流, 此时降雨对河道内污染物的冲刷与输移作用极为有限。然而, 当降雨强度突破地表下渗能力与土壤包气带的饱和阈值时, 便会骤然引发强烈的冲刷效应, 导致大量面源污染物在短时间内集中汇入河网。通过端到端的联合训练, 本模型能够自动评估当前气象事件的冲击力度, 并在无需人为设定先验阈值的前提下, 隐式学习这一复杂的物理边界。在极端情形下, 当 $\lambda_t \rightarrow 1$ 时, 模型主要由气象驱动特征主导, 适用于暴雨、洪水等情景。当 $\lambda_t \rightarrow 0$ 时, 模型退化为以水质自身演化为主的自回归模式, 适用于长期无雨或水文条件稳定的阶段。

相较于简单的特征拼接, 该机制不仅能根据实时水文情境动态分配不同物理量特征的贡献权重, 有效避免了常态下微小气象噪声的干扰, 还极大地提升了深度学习模型在不同水文期下的物理可解释性。通过在推理阶段可视化 λ_t 的时序演化曲线, 可以直接反映气象驱动在不同阶段对水质变化的影响程度, 从而为后续模型验证与黑盒结果解释提供直观的水文学依据。

4.3.3 输出层设计与多步预测稳定性

在通过物理门控机制获得深度耦合的时空综合特征 $H_{final,t}$, 模型需要将这一高维隐式表征解码, 并映射回实际的物理观测空间。为此, 本文采用全连接层作为输出解码器, 实现未来 T_{out} 个时间步的预测:

$$Y = \{X_{t+1}, \dots, X_{t+T_{out}}\} = \text{Linear}(H_{final,t}) \quad (4-14)$$

其中, $Y \in \mathbb{R}^{T_{out} \times N \times C}$ 为模型最终输出的时空预测张量, 包含 N 个站点在未来 T_{out} 个时间步上的 C 种水质参数演变轨迹。

在多步时间序列预测任务中, 常见的解码策略主要分为递归多步预测与直接多步预测。传统方法多采用递归策略, 即通过单步模型自回归地将上一时刻的预测值作为下一时刻的输入。这种方式在平稳序列的短期预测中表现尚可, 但在受气象强驱动的流域水质中长期预测中存在严重的局限性。由于水质演化常伴随突发性的气象脉冲(如暴雨冲刷), 一旦单步预测在复杂水文事件中产生偏差, 该误差将被直接馈入下一个预测循环, 导致预测误差随时间步的推移呈指数级累积放大。

为突破这一瓶颈, 本文的输出层坚决采用了直接多步预测策略。如公式 (4-14) 所示, 模型通过线性映射一次性并行生成未来 T_{out} 个时间步的全部预测结果, 从根本上切断了误差在时间轴上自回归放大的传导路径。这种设计极大地提升了模型在执行中长期水质预测任务时的数值稳定性。更重要的是, 直接多步输出策略与前

述的动态图卷积（捕捉瞬态空间拓扑）以及门控融合机制（自适应评估气象脉冲强度）形成了闭环的优势互补。在面对极端气象条件引发的突发水文事件时，该端到端的架构能够更加敏锐、鲁棒地刻画出水质的非平稳演化轨迹，从而满足实际流域管理中对突发水污染预警的时效性与准确性需求。

第5章 实验和结果分析

5.1 实验设置

本章围绕第四章所提出的基于气象感知动态图卷积网络（MD-DySTGCN），通过系统化的实验设计与对比分析，全面验证模型在汉江流域水质预测任务中的有效性、稳定性及结构合理性。实验设计遵循科学性与可复现性原则，从模型横向对比与内部结构消融分析两个层面展开，力求从结果层面与机理层面同时支撑本文所提出模型的创新性与实用价值。

在实验过程中，所有对比模型均基于相同的数据划分方式、输入输出设置及评价指标进行训练与测试，确保实验结果的可比性。通过构建由浅入深、由简单到复杂的模型对比体系，本节不仅关注 MD-DySTGCN 在预测精度上的提升幅度，更强调模型在刻画流域水质时空演化规律方面所体现出的结构优势。

5.1.1 对比实验设计

为了客观评估 MD-DySTGCN 模型的预测性能，并准确定位其在水质预测与时空建模领域中的技术水平，本文选取了 11 种具有代表性的基线模型作为对比对象。这些模型覆盖了统计学方法、传统机器学习模型、深度纯时间序列模型、先进的大型时序架构，以及典型的时空图神经网络模型，构成一个层次清晰、覆盖全面的对比实验体系。

从实验设计角度看，上述基线模型的选取并非简单的罗列，而是形成了一个严格的演进谱系。由低复杂度向高复杂度递进，由单变量独立预测向多变量协同建模演化，由纯时间维度特征提取向显式时空联合建模过渡，最终由静态空间拓扑向自适应图结构延展。通过此组对比实验，旨在深入探讨并回答以下关键研究问题：在复杂的汉江流域水质预测任务中，深度学习模型相较于传统方法的性能边界在哪；仅依赖时间维度建模是否足以刻画流域水质的演变过程；预设或自适应的静态空间拓扑在流域时空建模中存在何种局限性；以及本文引入的气象驱动动态空间结构是否能够有效应对水环境的瞬时突变并带来显著的预测收益。

（1）基准模型

为了全面评估本研究的效果，各基准模型的基本原理余在水质预测中的特性定位如表 5-1 所示。

表 5-1 基准模型介绍

基准模型	描述
HA	历史平均模型，基于历史时间窗口内观测值的算术平均进行预测，用于构建最基础的性能下界。
ARIMA	差分自回归移动平均模型，通过差分、自回归和移动平均项对时间序列进行建模，刻画水质变化中的线性依赖关系。
SVR	支持向量回归，基于支持向量机的回归模型，利用核函数刻画非线性时间序列特征。
TCN	时间卷积网络，采用因果卷积与空洞卷积结构，在保证时间因果性的同时扩大感受野，实现高效时间特征提取。
LSTM	长短期记忆网络，通过引入独特的门控机制（遗忘门、输入门、输出门）和记忆单元，克服了传统 RNN 在长序列训练中的梯度消失问题，能够有效捕捉水质数据演变过程中的长短期非线性依赖关系。
Informer	基于稀疏自注意力机制的高效 Transformer 模型，是长序列时序预测领域的经典基线。
PatchTST	基于局部切片与通道独立策略的时序模型，能有效保留水质局部语义并避免多变量噪声干扰。
Crossformer	专为多变量时间序列设计的 Transformer 模型，通过跨维度注意力机制显式捕捉不同水质参数间的理化关联。
GCN-LSTM	利用静态邻接矩阵进行图卷积建模空间依赖，并通过 LSTM 捕捉时间动态变化。
Graph WaveNet	结合空洞因果一维卷积与自适应图卷积结构，在训练过程中自动学习节点间潜在空间关系。
MTGNN	多变量时间序列图神经网络，通过图学习模块自动生成邻接矩阵，并利用多尺度卷积同步建模时空特征。

（2）数据集划分与评估策略

本节对比实验所采用的数据集为经过第三章预处理流程处理后的汉江流域水质监测与气象特征联合数据集。考虑到汉江水系的物理拓扑结构与流域演变规律，实验选取位于汉江最下游的“宗关”断面作为核心评估与测试对象。宗关断面不仅是武汉市重要的饮用水源地取水口，且位于汉江汇入长江的交汇口附近，客观上汇集了全流域的径流变化与污染负荷，具有最复杂的时空累积效应与非线性特征。在该断面进行评估，最能严苛检验各模型对长距离空间依赖关系以及全流域信息的特征聚合能力。为保证模型训练与评估过程中严格防止未来信息泄露，数据严格按照时间发生顺序划分为训练集、验证集和测试集，划分比例为 7:1:2。

针对不同架构模型的公平性对比，本实验设计了统一的基准评估策略，进行输入维度差异化和输出评估统一化。传统机器学习与纯时间序列深度学习模型（如 ARIMA、SVR、LSTM、PatchTST 等）采用单站点独立建模，仅输入宗关断面的 9 项水质历史参数；而时空图神经网络模型（如 GCN-LSTM、Graph WaveNet、MTGNN 等）则采用多站点联合建模，输入全流域 16 个站点的 9 项水质参数以提取空间协同关系。特别地，仅本文提出的 MD-DySTGCN 模型额外独占引入了 4 维气象参数（气温、降水、径流、风速），以驱动动态图的生成。时空图神经网络在解码阶段输出全流域 16 个站点的预测张量，但在最终计算 RMSE、MAE 等全局评价指标时，

统一通过索引掩码切片，单独提取出“宗关”断面的预测结果，使其与单站点模型的输出形状与评估目标严格对齐。

(3) 模型训练主要参数配置

为确保不同架构的模型在公平的基础线上进行训练博弈，本实验构建了统一的网络优化框架。考虑到真实环境下的水质监测数据不仅包含由气象驱动的物理突变，还不可避免地夹杂着由传感器漂移或设备故障引起的极端异常噪声，本实验摒弃了传统的均方根误差，选用更具鲁棒性的 Huber Loss（平滑 L1 损失）作为反向传播的损失函数。该损失函数结合了均方误差与绝对误差的双重优势：在预测误差较小时表现为平方惩罚，以加速模型收敛至全局最优；而在面对极端离群值时，则自动平滑为线性惩罚，从而有效防止深层网络的梯度更新被异常尖峰过度带偏，赋予模型极强的抗噪声干扰能力。

在参数优化层面，模型单次前向传播的批量大小设定为 64，并采用初始学习率为 0.001 的 AdamW 优化器（解耦权重衰减的自适应优化器）进行网络参数的梯度更新。相较于传统优化算法，AdamW 将正则化惩罚项进行了严格的数学解耦，能够更纯粹地限制 MD-DySTGCN 等复杂时空图网络参数空间的过度膨胀，从而显著提升模型在未知气象突变场景下的泛化能力。本对比实验的主要全局参数配置如表 5-2 所示。

表 5-2 模型训练主要参数

参数项	参数值	说明
输入历史步长	$T_{in} = 168$	对应过去 28 天的连续观测数据
输出预测步长	$T_{out} = 12$	对应未来 48 小时的水质预警跨度
Batch Size	64	单次迭代输入网络的样本数量
初始学习率	0.001	优化器权重更新的初始步长
优化器	AdamW	解耦权重衰减的自适应优化器，有效抑制深层时空图网络的过拟合，提升泛化能力。
权重衰减系数	1×10^{-4}	配合 AdamW 使用的正则化惩罚项，限制参数空间膨胀
损失函数	Huber Loss	稳健型分段损失函数，兼顾小误差的快速收敛与对极端水质传感器噪声的强抗干扰能力

为了兼顾模型在时间维度上的理论感受野与实际水务预警的工程需求，本研究对核心时空窗口进行了针对性设计。在统一将数据采样频率重采样为 4 小时/次的基础上，构建了如下时空切片：

输入历史步长为 168，对应过去 28 天的连续观测窗口。从水文物理机制来看，流域水质的演变不仅受短期降雨的脉冲影响，更具有显著的中长期累积效应。例如，农业面源污染的地表冲刷、汇流及河道降解通常需要数周的时间跨度。长达 1 个月的历史感受野恰能完整覆盖一个中短期气候干湿交替周期，从而引导图神经网络充分捕捉污染物“累积-释放-传输”的长效滞后规律。

输出预测步长为 12，对应未来 48 小时的水质预警跨度。在真实水环境管理中，单步预测虽然数值精度较高，但留给环保部门的应急响应时间过短。将预测视窗前瞻至 48 小时，不仅为下游宗关水厂调整加药策略或切换备用水源提供了充裕的“黄金调度窗口”，也契合了上游丹江口水库生态补水的标准调度周期。同时，由于未来 48 小时内的气象预报数据通常具有极高的置信度，该步长设定能最大化发挥“气象驱动”模块的效能，避免因长远期气象预测偏差而导致误差级联放大。

(4) 实验环境及设置

本文所涉及的所有模型的代码编写、训练、验证与测试过程，均在统一的实验环境下独立运行。实验运行平台为实验室高性能计算服务器，具体软硬件配置如表 5-3 所示。通过统一固定的实验平台、随机种子以及底层算子，本研究有效排除了由于硬件浮点计算差异或环境依赖不同对模型性能评估造成的偶然性干扰，确保了各项对比实验的绝对公平与可复现性。

表 5-3 实验软硬件配置信息

软件/硬件	版本/配置
CPU	Intel Xeon 系列处理器
GPU	NVIDIA GeForce RTX 3090
内存	128 GB
硬盘	2 TB
操作系统	Ubuntu 20.04
Python	3.8
PyTorch	1.12
CUDA	11.3
cuDNN	8.2

5.1.2 消融实验设计

MD-DySTGCN 模型主要由气象驱动输入模块、动态图构建机制、物理感知门控融合单元以及时间编码模块四个核心组件构成。为遵循控制变量原则，消融实验仅对其中单一模块进行移除或替换，其余网络结构、训练策略及参数设置均保持一致。

本文共设计了四种消融实验变体模型，具体说明如下：

(1) w/o Meteo（移除气象驱动模块）：该变体在模型输入阶段仅使用历史水质序列作为输入，不再引入 ERA5 气象相关变量。同时，由于缺乏气象驱动信息，动态图构建模块失效，模型中的邻接矩阵退化为基于站点空间距离构建的静态邻接矩阵。

(2) w/o Dynamic Graph（移除动态图机制）：该变体保留水质与气象双塔结构，但强制邻接矩阵在所有时间步保持不变。动态图生成器被替换为固定的静态图结构，用于验证随时间变化的空间拓扑在水质预测中的必要性。

(3) w/o Gated Fusion（移除物理门控融合机制）：在该变体中，保留气象输入

与动态图构建模块，但在特征融合阶段不再采用物理感知门控单元，而是将水质特征与气象特征通过简单拼接方式进行融合，以分析门控机制在多源特征融合中的作用。

(4) w/o TCN（时间编码器替换为 LSTM）：该变体将模型中的时间编码模块由 TCN 替换为 LSTM 网络，其余模块保持不变，用于比较卷积式时间建模结构与循环神经网络在长时间序列预测任务中的性能差异。

各消融模型的结构差异及验证目标汇总如表 5-4 所示。

表 5-4 消融实验模型设置

模型名称	气象输入	图结构	融合方式	时间编码器
MD-DySTGCN	yes	动态图	门控融合	TCN
w/o Meteo	no	静态图	-	TCN
w/o Dynamic Graph	yes	静态图	门控融合	TCN
w/o Gated Fusion	yes	动态图	拼接融合	TCN
w/o TCN	yes	动态图	门控融合	LSTM

为保证实验结果的公平性与可比性，消融实验与对比实验采用相同的实验环境、训练策略及评价指标，仅对模型结构中的关键模块进行消融。

5.2 结果分析

本节将对 MD-DySTGCN 模型在汉江流域“宗关”断面的实验结果进行详细剖析。分析过程遵循“由训练到测试、由整体到局部、由数值到机理”的逻辑主线。首先分析模型的训练收敛特性，随后通过多项评价指标与基线模型进行横向对比，接着通过消融实验验证核心模块的贡献，最后通过可视化手段直观展示模型的预测能力与物理可解释性。

5.2.1 训练过程分析

模型在训练过程中的损失函数下降曲线是评估模型学习能力、参数优化效率及架构合理性的核心依据。图 5-1 展示了 MD-DySTGCN 与其余 8 种代表性基线模型在训练集上的损失变化趋势。得益于本实验统一采用的 AdamW 优化器与 Huber Loss 损失函数，各模型在训练过程中均未出现剧烈的梯度爆炸现象，但在收敛速度与最终的拟合下限上展现出了显著的架构差异。




图 5-1 模型训练过程的损失函数变化曲线

从图 5-1 的收敛轨迹中可以直观地观察到，不同基线模型在面对高度复杂的动态水文环境时呈现出截然不同的学习瓶颈。以 GCN-LSTM 为代表的传统时空联合模型表现出了较弱的拟合能力，其损失曲线在初期小幅下降后便迅速陷入停滞状态。引入自适应图结构的 Graph WaveNet 虽然收敛趋势相对正常，但整体误差下降极其缓慢。这表明，预设的静态空间拓扑结构或更新迟缓的自适应矩阵会给模型的参数优化带来巨大阻力，难以有效拟合受气象突变强迫的水质非线性波动。与此同时，以 PatchTST、Informer 和 LSTM 为代表的纯时间序列模型则在训练的极早期（前 3 到 5 个 Epoch）展现出了惊人的收敛速度，损失值迅速探底。这主要归功于 PatchTST 等模型采用的通道独立策略，使其只需专注挖掘单一水质变量的历史自回归规律，大幅简化了初期的学习任务。然而，由于缺乏对跨站点空间协同与外部气象特征的感知，这类纯时序模型在 Epoch 10 之后便早早触及了拟合能力的“天花板”，曲线演变为一绝对平坦的渐近线，无法进一步捕捉更深层次的时空演变细节。

相比于上述两类基线模型，本文提出的 MD-DySTGCN 模型展现出了极强的深层特征学习上限与稳健的突破能力。在训练初期，由于模型需要同时优化气象驱动双塔模块、动态图生成器以及门控融合单元，其庞大且复杂的参数空间使得初始收敛速度略逊于 PatchTST 等纯时序模型。但随着训练的推进（Epoch 10 至 20 期间），MD-DySTGCN 凭借时间卷积网络的大感受野与残差连接设计，实现了梯度在深层网络中的高效传播。更为关键的是，模型内部的动态图结构在这一阶段开始精准捕获气象驱动下的水流拓扑形变规律。在 Epoch 25 左右，MD-DySTGCN 的训练损失成功向下“击穿”了所有纯时序模型所面临的瓶颈底线，并在后续迭代中平稳收敛至全场最低的绝对误差水平。这一过程充分论证了引入气象先验与动态图机制虽在初期增加了学习难度，但从根本上拓宽了模型对真实流体环境的拟合容量。

5.2.2 对比实验结果分析

为了消除不同水质参数之间巨大绝对量纲对全局损失函数的过度主导，本节实验统一在标准化空间内计算均方误差（MSE）、均方根误差（RMSE）与平均绝对误差（MAE），以确保 9 项水质特征在性能评估时保持严格的等权重分布。此外，考虑到标准化数据中存在零值及负值，平均绝对百分比误差（MAPE）的计算均在对预测输出反归一化至原始物理量纲后进行，以真实反映模型在实际业务场景中的相对偏离度。表 5-5 详细展示了 MD-DySTGCN 与 11 种基线模型在宗关断面进行多步长预测的综合性能评估结果。

表 5-5 不同模型在测试集上的预测性能对比

指标	MAE		RMSE		MSE		MAPE	
模型名称	训练集	测试集	训练集	测试集	训练集	测试集	训练集	测试集
HA	0.4837	0.4913	0.6751	0.6839	0.4558	0.4677	22.97%	23.14%
ARIMA	0.2153	0.2198	0.3758	0.3831	0.1412	0.1468	9.13%	9.56%
SVR	0.2274	0.2364	0.3908	0.4021	0.1527	0.1617	9.23%	9.73%
LSTM	0.1897	0.2756	0.3063	0.4261	0.0938	0.1816	8.62%	12.77%
TCN	0.1763	0.2071	0.2847	0.3368	0.0811	0.1134	8.07%	10.04%
Informer	0.1971	0.2438	0.3274	0.3773	0.1072	0.1424	9.52%	11.61%
PatchTST	0.1583	0.1754	0.2601	0.2912	0.0677	0.0848	7.28%	8.07%
Crossformer	0.2863	0.3597	0.4392	0.5458	0.1929	0.2979	13.97%	17.07%
GCN-LSTM	0.2714	0.4213	0.4148	0.6374	0.1721	0.4063	13.21%	20.27%
Graph WaveNet	0.1924	0.2493	0.3113	0.3917	0.0969	0.1534	8.94%	11.68%
MTGNN	0.1774	0.2261	0.2934	0.3691	0.0861	0.1362	8.11%	10.53%
MD-DySTGCN	0.1407	0.1634	0.2326	0.2649	0.0541	0.0702	6.48%	7.67%

从全局指标分布来看，本文提出的 MD-DySTGCN 模型在四大评价指标上均取得了全场最优表现。通过对不同模型架构的横向与纵向深度对比，可以清晰地观察到各类网络在复杂水文预测中的瓶颈与优势。与预期不同，早期的时空联合模型在本实验的长步长预测中出现了严重的性能劣化，其测试集 RMSE 高达 0.6374，甚至劣于纯时序的 TCN 模型。这一现象深刻揭示了传统图网络的结构性缺陷：GCN-LSTM 采用基于地理距离预设的静态邻接矩阵，在面对因气象突变（如暴雨）导致的水文传输速率剧烈变化时，静态图不仅无法提供有效的空间协同，反而会将上游的无关噪声强

制聚合至下游节点，引发误差在多步自回归中的级联放大。引入自适应图结构的 Graph WaveNet 与 MTGNN 虽然在一定程度上缓解了静态图的刚性问题，但由于缺乏对外部气象先验的感知，其动态调整依然存在明显的滞后性。

在纯时间序列模型阵营中，基于 Transformer 架构的 PatchTST 展现出了极其优异的性能，其测试集 RMSE 低至 0.2912，大幅超越了复杂的时空图网络 MTGNN。PatchTST 的成功印证了通道独立策略在复杂水环境预测中的有效性，即通过切断不同水质变量间的直接注意力交互，能够有效屏蔽跨变量的异质噪声干扰。反观同样作为先进大模型的 Crossformer，由于其强制计算跨维度注意力，在信噪比极低的水质数据中引入了巨大的冗余信息，导致其测试集 RMSE 暴跌至 0.5458。然而，PatchTST 尽管时序拟合能力极强，但其割裂空间拓扑的本质属性，注定了它在面对上下游污染物物理传输时会产生不可逆的空间感知盲区。

本文提出的 MD-DySTGCN 模型在测试集上实现了 0.2649 的极低 RMSE 与 7.67% 的极低 MAPE。相较于全场最强基线 PatchTST，本模型的 RMSE 与 MAE 分别进一步显著降低了约 9.03% 与 7.13%。这一显著的性能跃升充分证明了本模型架构设计的先进性与物理合理性。此外，对比表 5-5 中的训练集与测试集指标可知，MD-DySTGCN 的训练集 MAPE 与测试集 MAPE 保持了极小的数值差距。这表明在物理感知门控融合机制与 Huber Loss 的协同约束下，模型有效过滤了水质传感器的极端离群噪声。该设计不仅实现了多源异构信息的高效融合，还有效抑制了复杂图网络架构易发的过拟合现象，使得模型在长时效的真实调度场景中展现出了极强的工程鲁棒性。

5.2.3 消融实验结果分析

为严谨验证 MD-DySTGCN 模型内部各核心组件的独立贡献与物理必要性，本节对比了完整模型与四个降级变体（w/o Meteo, w/o Dynamic Graph, w/o Gated Fusion, w/o TCN）在测试集上的预测性能。考虑到不同水质指标对环境强迫的响应机制存在显著差异，为直观展现各消融模块对特定水文特性的物理影响，本节特别提取了受降雨地表冲刷影响剧烈的浊度以及受气温水文交替主导的溶解氧作为典型代表。图 5-2 详细展示了各变体在这两项指标上反归一化至原始物理量纲后的绝对预测误差（RMSE 与 MAE）对比。




图 5-2 浊度 TURB 和溶解氧 DO 的预测误差对比

实验结果清晰地表明，完整模型在两项核心水质指标上均探底了最低的预测误差，溶解氧 RMSE 低至 0.256 mg/L，浊度 RMSE 低至 14.06 NTU。而不同模块的消融则引发了具有明确物理指向的性能衰减。移除气象输入（w/o Meteo）导致了最剧烈的系统性崩溃。从图 5-2 可以观察到，该变体的浊度 RMSE 呈现出断崖式上升，从 14.06 NTU 骤增至 22.41NTU，溶解氧 RMSE 也升至全场最高的 0.319 mg/L。这从根本上证实了降雨、径流等外部环境边界条件是打破水系原有周期、驱动水质突变的核心先验要素。单纯依赖历史水质序列的水文惯性，在面对极端气象强迫时将彻底丧失对污染峰值的预警能力。

动态拓扑退化（w/o Dynamic Graph）引发了显著的空间感知滞后。将气象驱动的动态图强制退化为基于地理距离的静态图后，浊度与溶解氧的 RMSE 分别大幅反弹至 18.67NTU 与 0.305 mg/L。这表明刚性的静态拓扑完全无法适应汉江流域显著的季节性水文变化（如汛期流速加快带来的上游快速冲刷）。而本文设计的动态图机制通过实时重构节点间的物理关联权重，有效保障了在复杂变动的水动力条件下，模型依然具备精准的长距离特征聚合能力。

时间编码器与特征融合方式的降级同样暴露了长序列建模中的结构瓶颈。当把时间卷积网络（TCN）替换为传统的双层 LSTM（w/o TCN）后，浊度 RMSE 回落至 15.33NTU。这有力验证了 TCN 独有的因果空洞卷积结构在处理长达 168 步的历史序列时，不仅规避了循环神经网络易发的误差累积与梯度衰减，更在保持时序长期记忆方面占据了绝对优势。与此同时，去除物理感知门控机制、改用直接拼接法进行特征融合（w/o Gated Fusion）后，两项指标的误差也出现了一定幅度的上升。这证明了门控机制在网络中充当了多源异质数据交互的“软开关”，它能够根据当前天气事件的极端程度，自适应地调节气象强迫与水质内因的流入比例，从而有效屏蔽了平水期的微小气象噪声对主干预测轨迹的线性干扰。

MD-DySTGCN 所展现出的最优性能，绝非多个深度学习流行组件的机械堆砌，而是气象驱动先验、动态图拓扑重构、门控自适应过滤与 TCN 高效并行架构深度耦合、协同演化的结果。

5.2.4 可视化分析

为更加直观地评估 MD-DySTGCN 模型在实际多变量水质预测任务中的拟合细节与时序响应能力，本节从宗关断面测试集中截取了包含 200 个时间步的连续时间片段，对 9 项水质指标的真实观测值与模型多步预测值进行了可视化对比，结果如图 5-3 所示。




图 5-3 宗关站点水质参数预测结果

从全局多变量联合演化的趋势来看，MD-DySTGCN 模型在绝大多数水质指标上均展现出了极高的轨迹跟踪精度，预测曲线与真实曲线在时间相位与演变形态上保持了高度一致。这直观地证明了模型不仅在宏观误差指标上表现优异，更在微观的时间动态刻画上具备强大的物理还原能力。

在 pH、溶解氧（DO）、高锰酸盐指数（CODMn）以及总磷（TP）、总氮（TN）等指标的预测中，模型的表现堪称优异。特别是当 DO 和 TP 出现剧烈的断崖式下降或脉冲式飙升时，红色预测线极其敏锐地贴合了真实的极值点。整个预测过程未出现传统时间序列模型常见的时间滞后现象，充分证明了 TCN 架构与气象驱动动态图在捕捉污染物快速理化反应时的零延迟预警能力。

浊度（Turbidity）、电导率（EC）和氨氮（NH₃-N）是对降雨径流和上游面源污染冲刷极其敏感的指标。从图中可以清晰观察到，在这些指标发生高频、剧烈震荡的

时段)，模型极其精准地预测了峰值爆发的时间位置。尽管在绝对振幅上，预测曲线对部分极高耸的尖峰存在一定程度的低估，但这本质上是由深度学习在拟合长尾分布数据时固有的回归均值倾向所致。从实际预警业务的角度来看，能够提前精准锁定突发污染事件的发生时间，其工程价值已远远大于对绝对峰值的完美拟合。

值得客观指出的是，在水温（WT）指标的预测中，尽管模型准确抓住了温度随昼夜与周期的起伏波形，但在前 120 个时间步内，预测值整体略高于真实观测值，存在轻微的系统性基线偏移。这主要是由于水质断面的实际水温不仅受宏观气温驱动，还受到局部微地形遮挡、水体分层以及传感器安装深度等微观热力学因素的干扰，而输入的大尺度 ERA5 气象数据难以完美解析这种极微观的环境噪声。

MD-DySTGCN 模型在多变量水质预测中兼顾了极高的趋势跟踪保真度与突发事件的敏锐嗅觉。可视化的结果进一步印证了气象驱动与动态构图机制的成功，证明该模型完全具备支撑流域水质实时预警调度的落地潜力。

第6章 基于大语言模型的智能预警系统设计与实现

在前文完成水质预测算法的构建与对比实验验证的基础上,为进一步探索该模型在复杂真实水环境管理中的工程应用价值,本章设计并实现了一套基于大语言模型的汉江水质智能预警系统。该系统将深度学习预测模型的“物理感知”能力与大语言模型的“认知推理”能力进行深度融合,旨在为汉江流域提供集数据汇聚、时空预测与智能诊断于一体的一站式决策支持平台。

6.1 系统需求分析与总体框架设计

在系统开发初期,需对汉江流域水质精细化管理的实际业务场景进行系统化梳理,明确软硬件架构的设计目标,从而为后续的数据库建模与模块开发提供规范化的指导标准。

6.1.1 功能与非功能需求分析

针对汉江流域水质多尺度演变特征及管理人员的实际决策需求,本系统的功能需求主要聚焦于多源数据治理、模型预测可视化、智能交互以及辅助决策四个维度。首先,系统需具备多源异构数据融合与管理能力,实现对地面水质监测点位数据与宏观气象驱动数据的统一接入。考虑到高精度气象数据客观存在的时延问题,系统还需支持历史典型事件的回放推演模式,以实现极端气象事件下的数据流动态对齐。其次,系统需在线加载训练完毕的水质预测算法模型权重,接收实时或回放的双流数据输入并输出多步水质预测结果,并在前端通过地理信息系统渲染流域拓扑全景看板与水质参数的动态演变趋势。

为突破传统固定图表展示的局限,本系统进一步引入基于大语言模型的智能体以实现自然语言交互。用户可通过对话框直接下达指令,触发系统底层的意图识别与工具调用,自动提取复杂预测数据并转化为通俗易懂的水情简报。当核心算法预测到未来水质指标存在突变或超标风险时,系统需自动触发越限预警。借助检索增强生成技术,系统能够自主从内置的《地表水环境质量标准》及流域应急预案库中提取强相关条目,为管理人员自动生成具备法规依据的污染处置与辅助诊断建议。

在满足上述功能特性的同时,为保障大语言模型与深度学习预测模型在同一工程框架下的高效协同,系统还需具备严格的非功能性指标。考虑到模型推理与文本生成均属于计算密集型任务,系统后端需采用异步非阻塞框架以保障水质预测接口的秒级响应,满足业务的实时性要求。系统应具备完善的异常捕获与容错机制,在外部气象数据源缺失或格式异常时,能够自动执行缺省值填补或平滑过渡。此外,整体架构需遵循“高内聚、低耦合”的设计原则,确保预测算法服务、智能体交互服务与业务逻辑

辑组件相互独立，以便于未来预测模型的迭代升级或大模型基座的无缝替换。

6.1.2 总体框架设计

基于前文的需求分析，并结合现代微服务与大模型应用的架构理念，本系统采用自下而上的四层分布式体系架构进行设计。整体框架自底向上依次划分为数据支撑层、算法引擎层、认知交互层与业务应用层。各层级职责明确、边界清晰，共同保障了“数据-模型-知识-应用”的高效流转。




图 6-1 系统总体框架图

数据支撑层是整个系统的物理存储基座，采用混合数据库架构以应对多模态数据的持久化管理挑战。该层主要包含两大核心组件：关系数据库（MySQL）与向量数据库。其中，关系数据库主要负责存储高度结构化的业务数据，如水质监测站点的空间拓扑信息、高频时序的实时与历史水质观测数据、气象驱动数据以及系统用户权限日志等；向量数据库则专门用于存储水环境管理规范及流域应急预案经过 Embedding 转化后的高维稠密向量，为上层 RAG 模块的语义相似度检索提供毫秒级的底层支撑。

算法引擎层是系统的核心算力与模型服务中心，集中封装了系统所需的“物理感知”与“认知生成”双重能力。该层涵盖三个关键模块：首先是在线数据预处理流，负责实时接收底层输入的多源数据，并执行缺失值填补、空间插值及时间滑窗切片等操作，将原始数据转化为标准的张量格式；其次是核心水质预测算法模块，部署了本研究构建的水质预测算法模型权重，通过前向推理持续输出多步水质演变趋势；最后是大语言模型（LLM）基座，系统将其作为底层生成式算力引擎进行本地化或接口化部署，为上层的复杂自然语言处理任务提供基础的理解与生成能力。

认知交互层充当系统的“智慧大脑”与任务调度中枢，主要负责大语言模型的业务编排与能力拓展。该层主要由智能体与检索增强生成两大模块构成。基于 ReAct 范式的智能体模块负责精准解析用户的自然语言指令，通过意图识别自主规划任务路径，并以工具调用的形式动态接入底层暴露的水质预测 API；RAG 模块则负责在对话过程中，根据当前上下文向底层的向量数据库发起语义检索，提取强相关的专业法规与预案片段，从而引导大语言模型生成具备事实依据的水情诊断与污染处置建议，有效避免了模型幻觉。

业务应用层作为直接面向流域管理人员的终端交互界面，通过前后端分离技术构建了响应式 Web 端应用。该层将复杂的底层数据与预测结果转化为直观的视觉表达，主要提供三大核心视窗：水质数据查询看板负责对流域历史与当前的水文气象要素进行多维度的统计与可视化展示；水质数据预测看板依托底层的水质预测算法，通过 GIS 引擎与 ECharts 组件，渲染出未来多时间步的水质演化态势与越限报警节点；智能交互问答窗口则提供仿人类对话式的 UI 界面，用户可在此以自然语言直接向系统发起提问，获取深度的趋势剖析与辅助决策报表。

6.2 系统数据库设计

6.2.1 数据库概念结构设计

数据库概念结构设计是构建系统底层数据架构的核心环节，其主要目的在于将汉江流域复杂的水环境监测业务、多维时空预测算法需求以及智能预警交互逻辑，抽象并转化为独立的数据实体及其拓扑关联关系。本研究采用实体-联系模型对业务领域进行自顶向下的建模，系统全局的数据库概念结构 E-R 图如图 6-2 所示。在系统的概念模型中，共提取并定义了七个核心实体，涵盖了从底层物理感知到上层智能决策的完整数据链路。




图 6-2 数据库表结构设计

针对流域水质演变过程中显著的空间拓扑关联性与时变特征，系统以站点信息实体作为物理环境数据的空间锚点。围绕该核心实体，系统构建了多组一对多（1:N）的映射关系：即单一监测断面在时间序列上关联多条水质检测数据与气象驱动数据。此种概念结构在数据底座层面实现了水质内部状态演变与气象外部强迫驱动的时空

严格对齐，为核心预测算法提供了规范化的多源异构输入张量。同时，模型在线推理输出的多步时序预测结果，亦通过一对多的拓扑关系持久化至预测结果实体中，为前端水质演变态势的实时渲染提供底层支撑。

为保障大语言模型智能体的持续迭代与问答交互的可追溯性，系统抽象出系统用户信息与智能预警交互日志实体。当算法模块监测到未来水质参数存在越限或突变风险时，系统将自动触发预警并生成交互日志。该日志实体同步关联用户外键与站点外键，完整记录了用户的自然语言指令与智能体生成的诊断反馈。该设计构筑了“人-机-环境”协同响应的闭环数据链路，满足了水环境精细化管理的审计需求。

针对水环境管理领域的非结构化知识管理需求，系统独立构建了知识库文档实体。该实体专门用于统筹管理《地表水环境质量标准》及汉江流域应急预案等文本切片，并通过引入向量标识符字段，打通了关系型数据库与专属向量数据库的映射通道。这一架构设计为大模型智能体的检索增强生成机制提供了坚实的领域知识溯源底座，保障了系统输出建议的科学性与合规性。

本系统的概念模型通过清晰的实体边界划分与严密的基数关系映射，实现了对多源时空数据感知、算法在线推演及智能辅助决策业务的高效抽象，在消除数据冗余的同时，遵循了关系型数据库的规范化设计原则。

6.2.2 数据表逻辑结构设计

本系统的核心关系型业务数据采用 MySQL 8.0 关系型数据库进行集中存储与全生命周期管理。作为底层数据基座，MySQL 凭借其出色的并发处理能力与完备的事务安全机制，能够有效支撑汉江流域多站点、高频次水质监测数据的稳定写入。同时，MySQL 提供了完善的多语言驱动接口，能够与系统后端的 FastAPI 服务框架及大模型 Agent 模块实现低延迟的数据交互。针对海量时序特征与非结构化知识文档，本系统采取“关系型数据库+向量数据库”的混合存储架构，其中 MySQL 主要负责系统元数据、业务流水及核心状态指标的持久化。

(1) 系统用户信息表

系统用户信息表用于持久化存储系统管理与运营人员的账户元数据。该表以 user_id 为唯一主键，密码字段采用哈希加密存储以保障信息安全。role 字段用于实现基于角色的访问控制，为系统前端的权限路由与大模型 Agent 的越权拦截提供身份凭证。

表 6-1 系统用户信息表

字段名	字段类型	字段名解释
user_id	bigint	用户编号（主键）
username	varchar(50)	用户名
password_hash	varchar(255)	加密密码
role	varchar(20)	用户角色

(2) 站点信息表

站点信息表主要记录汉江流域各水质监测断面的静态空间拓扑属性。该表是连接各项业务数据的核心枢纽，通过 `station_id` 与其他动态数据表建立外键约束。并记录站点经纬度坐标为气象特征的空间映射提供精确的地理空间基准。

表 6-2 站点信息表

字段名	字段类型	字段名解释
station_id	bigint	站点唯一标识（主键）
station_name	varchar(100)	站点名称
longitude	deimal(10,6)	经度
latitude	decimal(10,6)	维度
city	varchar(50)	所属城市

(3) 水质检测数据表

水质监测数据表用于存储各断面历史及实时的水质理化指标序列。表内涵盖了与 MD-DySTGCN 模型输入特征严格对齐的 9 项关键参数，数据类型统一为浮点型以保证计算精度。该表以时间戳（`record_time`）和站点标识为联合检索条件，为预测模型提供高密度的时序训练与推理样本。

表 6-3 水质检测数据表

字段名	字段类型	字段名解释
record_id	bigint	记录流水号（主键）
station_id	bigint	关联站点编号（外键）
record_time	datetime	检测时间
DO	float	溶解氧
COD_MN	float	高锰酸钾指数
NH3_N	float	氨氮
TN	float	总氮
TP	float	总磷
PH	float	酸碱值
WT	float	水温
TURB	float	浊度
EC	float	电导率

(4) 气象驱动数据表

气象驱动数据表专门用于结构化存储经时空对齐处理的 ERA5 气象再分析数据。该表将宏观网格气象场降尺度映射至具体监测断面，包含降水量、地表径流等 4 项核心物理强迫变量，为 MD-DySTGCN 模型动态构建时空图拓扑结构提供关键的外部驱动力数据。

表 6-4 气象驱动数据表

字段名	字段类型	字段名解释
meteo_id	bigint	气象记录 id（主键）
station_id	bigint	关联站点编号
record_time	datetime	气象对齐时间戳
precipitation	float	总降水量
surface_runoff	float	地表径流
air_temp_2m	float	2 米气温
wind_speed_10m	float	10 米风速

（5）模型预测结果表

模型预测结果表（如表 6.5 所示）用于落盘 MD-DySTGCN 算法在线推理生成的多步预测结果。为支持预测误差的离线回溯与时效性分析，表结构中严格区分了预测基准时间（base_time，即输入序列截断时刻）与预测目标时间（target_time）。存储的预测数值将直接供前端趋势图表渲染及智能预警引擎调用。

表 6-5 模型预测结果表

字段名	字段类型	字段名解释
pred_id	bigint	预测记录 id（主键）
station_id	varchar	关联站点编号（外键）
base_time	datetime	预测基准时间
target_time	datetime	预测目标时间
pred_DO	float	预测溶解氧
pred_COD_MN	float	预测高锰酸钾指数
pred_NH3_N	float	预测氨氮
pred_TN	float	预测总氮
pred_TP	float	预测总磷
pred_PH	float	预测酸碱值
pred_WT	float	预测水温
pred_TURB	float	预测浊度
pred_EC	float	预测电导率

（6）知识文档表

知识库文档表是构建水质智能体检索增强生成架构的元数据字典。该表不仅存储了《地表水环境质量标准》、应急调度预案等领域非结构化文本的切片内容，还通过 vector_id 字段映射底层的专属向量数据库，从而支撑大模型针对水质超标事件的高效语义召回与知识溯源。

表 6-6 气象驱动数据表

字段名	字段类型	字段名解释
doc_id	int	文档 id（主键）
title	varchar	预案/标准名称
content_text	text	文档文本内容
vector_id	varchar	关联向量库 id
upload_time	datetime	入库时间

（7）智能预警交互日志表

智能预警交互日志表主要记录系统运行期大模型 Agent 与用户的指令交互及诊断决策链路。该表完整保留了异常触发节点、用户输入的自然语言提示词以及 Agent 融合预测数据与检索知识后输出的诊断策略。此设计不仅满足了安全审计与责任追溯的需求，也为后续垂直领域大模型的微调对齐积累了高质量的语料样本。

表 6-7 智能预警交互日志表

字段名	字段类型	字段名解释
log_id	bigint	交互日志流水号（主键）
station_id	varchar	关联站点编号（外键）
user_id	int	提问/处理用户（外键）
alert_level	int	警告等级
user_query	text	用户自然语言提问
agent_response	text	大模型诊断回复
create_time	datetime	交互发生时间

6.3 水质预测模块设计与实现

水质预测模型服务模块是本系统的核心计算中枢，主要负责接收前端指令、调度多源异构数据并驱动底层水质预测算法模型完成多参数的时空推演。从系统级交互视角来看，该模块的完整运行生命周期涵盖了预测请求、数据准备与对齐、模型推理以及结果处理与分发四个核心阶段。其详细的模块交互控制与网络通信数据流向如图 6.4 所示。




图 6-3 水质参数预测模块时序图

6.3.1 数据时空对齐与预处理接口

数据时空对齐与预处理接口主要负责在执行模型在线推理前，将离散、多源异构的原始业务数据转化为符合深度学习框架运算标准的特征张量。该过程涵盖了时序图中的预测请求阶段与数据准备与对齐阶段。

(1) 预测请求与鉴权阶段

系统交互始于前端 Web 管理界面。用户或系统定时任务向后端的 FastAPI Web 服务提交包含目标站点列表、预测时间基准及目标水质参数的 HTTP POST 请求。FastAPI 框架在接收到网络请求后，通过中间件拦截该请求，并执行 Token 身份合法性验证与请求参数的完整性校验。鉴权通过后，系统开启异步非阻塞的数据处理线程。

(2) 数据准备与对齐阶段

为保障预测模型输入特征的空间一致性，FastAPI Web 服务首先向 MySQL 数据库发起查询，精确定位目标站点的空间拓扑坐标。随后，Web 服务根据预测时间窗口，向 MySQL 数据库发起多表联合查询，提取涵盖当前时间基准的历史水质时序数据，以及对应的 ERA5 气象强迫驱动数据。

在成功获取双流历史数据集后，Web 服务内部调用预处理接口，触发数据清洗与转换流水线。预处理模块依次执行三层核心逻辑：首先，针对序列中的缺失值采用

线性插补或历史均值填补算法；其次，依托获取的空间坐标，利用双线性插值算法将网格化气象场精准映射至离散的监测断面，实现时空严格对齐；最后，加载训练阶段固化的均值与标准差字典，对对齐后的数据执行 Z-Score 归一化处理。处理完毕后，接口将高维标准化的特征张量返回至 Web 服务的业务逻辑层，为核心算法的推演提供高质量的数据底座。

6.3.2 水质预测模型推理部署

模型推理部署模块旨在将处于离线静态权重的水质预测算法转化为可提供高并发在线服务的水质推演引擎。该环节对应时序图中的模型推理阶段与结果处理与分发阶段。

（1）模型推理计算阶段

考虑到深度学习网络在实例化时较高的显存占用，Web 服务在系统启动阶段已通过单例模式加载了最优的模型权重。当接收到预处理完毕的特征张量后，FastAPI Web 服务通过远程过程调用机制或内部进程通信，触发底层水质预测算法模型的前向传播过程。在计算图内部，模型动态生成气象感知邻接矩阵，并通过双塔 TCN 与动态图卷积模块进行时空特征的深度融合与推演，计算得出各参数的水质预测数值，最终向 Web 服务返回包含未来 T_{out} 个时间步的预测结果张量。

（2）结果处理与分发阶段

Web 服务的业务逻辑层在捕获到预测张量后，首先挂载反归一化算子，将无量纲的数学张量还原为具有实际物理意义的浓度数值。为保障预测数据的可追溯性与后续大模型智能体的调用需求，Web 服务将解析后的预测结果批量写入 MySQL 数据库的 prediction_result 表中进行数据持久化操作。

待数据库返回落库成功的回执后，系统将多步预测数据封装为轻量级的 JSON 格式报文，利用 HTTP 响应或建立好的 WebSocket 全双工通道推送至前端 Web 管理界面。前端接收到数据流后，立即触发底层的 ECharts 渲染引擎，完成水质动态演变趋势折线图的重绘与超标预警状态的实时展示，至此完成一次完整的水质智能预测系统闭环交互。

6.4 智能预警 Agent 模块设计与实现

海量的高频预测数据若仅通过图表展示，依然高度依赖管理人员的个人经验进行风险研判。为最大化利用底层预测数据并赋予系统认知推理能力，本系统在应用层之上设计了智能预警 Agent 模块。该模块作为连接底层数据源与上层业务决策的智能中枢，依托大语言模型构建了包含“被动触发：自动预警与研判分发”与“主动交互：用户自然语言问询”的双引擎工作流。该模块的完整时序交互与系统控制流向如图 6-4 所示。




图 6-4 智能预警 Agent 模块时序图

6.4.1 自动预警与研判分发机制

自动预警流程是系统保障流域水环境安全的底层防御机制，采用异步事件驱动架构设计，对应时序图中的流程一。该流程依托大语言模型深厚的语义理解与内化知识，对异常水文状态进行智能分析，核心在于实现“毫秒级感知”与“专家级诊断”。

(1) 事件监听与阈值匹配

当底层时空预测模型完成一轮推演，并将预测结果成功写入 MySQL 数据库的 prediction_result 表后，系统内部的事件总线会立即派发预测完成事件，被动触发预警 Agent 服务。Agent 随即向数据库发起查询，提取最新生成的多步水质预测结果及对应的《地表水环境质量标准》国标阈值配置。随后，Agent 在内存中调用规则引擎执

行硬边界比对，若判断未来某时间步的水质参数存在越限或突变风险，则立即启动预警封装逻辑。

（2）大模型诊断与分发持久化

在确立预警目标后，Agent 会将异常发生的时间、空间坐标、超标参数及关联的气象强迫特征进行结构化拼接，组装为包含丰富系统上下文的提示词，并发送至大识，快速进行超标溯源推理，并返回结构化的预警报告及应急处置建议。

为满足后续的审计与追溯需求，Agent 将该次预警记录及 LLM 生成的诊断报告同步写入数据库的交互日志表（alert_chat_log）中进行持久化存储。最终，Agent 将封装好的预警通知数据包通过建立的 WebSocket 全双工通道主动推送至前端，触发 Web 大屏的声光告警弹窗，并同步渲染大模型的深度分析结果，实现了从数据异动到决策下发的全自动闭环。

6.4.2 用户自然语言问询与深度分析机制

为突破传统可视化监控面板单向数据展示的局限性，增强系统的决策辅助支持深度，Agent 模块设计了基于自然语言的主动交互问答引擎，对应时序图中的流程二。

（1）意图识别与数据上下文组装

管理人员可在前端 Web 界面的交互对话框中，针对当前流域水质状态或特定站点的历史告警输入自然语言疑问（如：“请结合近期气象条件，分析宗关站点未来 24 小时的总磷变化趋势及潜在风险”）。预警 Agent 服务接收到该文本流后，首先执行意图识别与实体抽取。随后，Agent 根据解析出的关键信息（站点、时间范围、水质参数），向 MySQL 数据库与时序数据库发起精准定向查询，提取关联的历史观测序列、模型预测序列以及 ERA5 气象驱动数据。

（2）动态 prompt 构建与流式推理展示

在获取到多维业务数据后，Agent 将用户的原始问题与结构化的业务数据上下文进行高度融合，动态构建出业务强相关的交互式 Prompt，并将其提交至底层大语言模型进行深度的语义推理与逻辑演绎。大模型在完成水质演变机理与数据态势的综合研判后，将定制化的解答文本以流式传输或完整报文的形式返回至 Agent 服务端。

Agent 服务在完成文本后处理后，将最终结果反向路由至前端 Web 界面，并在前端以气泡对话框的 UI 组件形式实时渲染 Agent 的专业回答。该交互机制有效降低了非专业管理人员的数据使用门槛，实现了数据价值向管理效能的直接转化。

6.5 系统原型运行实例展示

本系统的 Web 前端基于 Vue.js 框架构建，后端采用 FastAPI 进行高性能异步驱动，接入大语言模型交互组件。系统界面采用响应式布局，能够适配不同分辨率的监控终端。本节通过具体运行实例展示系统各核心功能模块的实际效果。

本系统的 Web 前端基于 Vue.js 框架进行组件化开发，整体 UI 采用暗黑科技主题，

以适应监控指挥大屏的视觉需求。系统整体架构采用响应式布局，左侧为功能导航侧边栏，清晰划分了“全景监控”、“预测分析”与“智能预警”三大核心业务模块；顶部区域为全局状态栏，实时展示当前系统时间及全流域 16 个站点的在线运行监控状态。本节将结合具体的系统运行截图，对各核心功能界面的工程实现效果进行实例展示。

6.5.1 汉江流域水质监控查询界面

全景监控页面是本系统的默认着陆页与核心数据检索视窗。该界面将多维数据报表查询与宏观地理空间展示相融合，旨在为管理人员提供详实、直观的水环境底座数据支持。该页面的实际运行效果如图 6-5 所示。




图 6-5 全景监控界面

针对复杂多变的流域水环境监管需求，该全景监控看板主要实现了以下三项核心业务功能：

(1) 多维灵活的参数报表检索机制

界面上半部分为“参数报表查询”模块。系统提供了高自由度的组合检索功能，用户可通过下拉菜单精准选定目标监测站点（如截图中展示的“皇庄”站）、自定义查询的时间滑窗，并支持对 12 项以上的水质与气象参数进行多选联动查询。后端 FastAPI 接收到查询指令后，迅速从底层关系型数据库中提取指定切片的数据，并通过前端的高性能表格组件进行分页渲染，实现了海量历史监测记录的秒级溯源。

(2) 多源异构数据的同屏融合展示

在参数报表的数据表格中，系统直观地体现了前期数据处理阶段的“时空对齐”成果。如表格列项所示，该业务模块不仅展示了水温、pH 值、溶解氧、高锰酸盐指数等常规水质状态变量，还同步并列展示气象驱数据动特征。这种水质与气象数据的同屏无缝融合，打破了传统环保系统与气象系统的数据孤岛，辅助管理人员直接从数据面板上洞察“水-气耦合”的物理关联。

(3) 流域站点的空间拓扑动态感知

界面下半部分为“水质监测站点分布”的 GIS 空间可视化模块。该模块集成了底层地图渲染引擎，采用暗色系卫星底图以突出数据层。系统根据数据库中 station 表存储的精准经纬度信息，将汉江流域的监测断面以动态发光节点的形式映射至真实地理空间中。节点颜色的状态能够直观反映当前站点的设备在线情况与整体水质健康度。该空间拓扑展示为后续水质预测模型提取上下游站点的空间邻接关系提供了直观的物理坐标依据。

6.5.2 水质参数预测分析看板

预测分析页面是本系统核心水质参数预测算法的工程化交互载体。该模块将复杂的深度学习网络前向推理过程封装为可视化的任务调度引擎，实现了水质演变从“被动监测”向“主动预测”的范式转变。该页面的实际运行效果如图 6-5 所示。




图 6-6 水质参数预测分析界面

为满足流域精细化、定制化的预测研判需求，该预测分析界面在交互流转与数据渲染上主要实现了以下三项核心功能：

(1) 参数化的预测任务配置与下发

界面左侧区域为“预测配置”表单控制台。管理人员可根据特定水文事件的需求，灵活指定预测的监测站点。同时，系统支持多目标参数的并发预测，用户通过多选下拉组件可自由组合所需的水质指标。在设定“预测基准时间”后，点击“开始预测”按钮，前端将向后端的 FastAPI 服务发送异步预测请求，触发底层的数据时空对齐、模型加载及 RPC 推理调用流程。

(2) 多参数时序推演结果的对比可视化

界面右侧为“预测结果”的核心渲染区，系统采用 ECharts 高性能图表库以卡片堆叠的形式同步展示多项水质参数的演变曲线。在图表设计上，系统对时间轴进行了严格的“过去-未来”物理切分：以预测基准时间为界，左侧区域绘制基于历史真实观测值的水质序列，右侧区域则动态渲染由水质参数预测算法模型输出的未来时间步

预测序列。以截图中的“浊度”预测图表为例，该可视化方案使管理人员能够直观对比历史波动与未来趋势，并借助下方的时间滑块灵活缩放查看特定时刻(的峰值细节。

(3) 推演数据的持久化与闭环管理

深度学习模型的单次推理结果不仅具有即时的展示价值，更是后续智能决策的重要依据。在界面右上角，系统提供了“保存结果”的交互入口。当管理员对当前轮次的预测拟合情况评估认可后，可通过该功能将内存中的高维预测张量转化为结构化记录，并批量写入底层 MySQL 数据库的 prediction_result 业务表中进行持久化落库。这一闭环设计不仅实现了推演数据的持久化留存，也为下一节将要展示的“智能预警 Agent”提供了可靠的业务上下文溯源底座。

6.5.3 极端天气下的智能预警与 Agent 交互案例

智能预警页面是本系统应用层的核心创新模块，也是前文所述“大语言模型认知交互层”的具体前端呈现。该界面彻底打破了传统水质监控系统“重展示、轻交互”的瓶颈，通过融合规则引擎与 LLM 问答大模型，实现了水环境风险的自动布控与深度辅助决策。该页面的实际运行效果如图 6-7 所示。



图 6-7 水质智能预警界面

基于 6.4 中设计的双引擎 workflow 架构，该交互界面在空间布局上被划分为左右两大核心功能区，分别对应系统的被动预警触发机制与主动对话问询机制：

(1) 动态预警阈值配置与状态监控模块

界面中左侧区域为系统被动预警的规则配置中枢。管理人员可针对不同水质指标灵活设定安全区间的上下限阈值。该模块直接与后端的预测数据流解耦并绑定：当底层水质参数预测算法模型将最新一轮的预测张量写入数据库后，系统的规则引擎会立即以毫秒级延迟将预测值与此处设定的阈值进行硬边界比对。界面下方的“活跃预警”面板则用于实时订阅并渲染超标告警事件。

(2) 基于自然语言的 AI 智能辅助研判引擎

界面右侧为占据主视觉的 AI 智能助手对话窗口，这是系统实现主动交互与认知

推理的核心载体。在 UI 交互设计上，该模块采用了类似主流大模型产品的气泡式对话流布局，极大降低了非计算机专业环保人员的使用门槛。当用户进入该界面时，Agent 服务会主动下发欢迎语及系统能力边界说明，并结合当前流域水文背景，动态推送启发式 Prompt 引导。

当用户在底部输入框提交业务指令后，前端将文本流通过 WebSocket 隧道发送至后端的智能体。随后，Agent 将在后台静默执行意图抽取、跨表联合查询以及 RAG 预案检索，最终将复杂的数据推理过程转化为结构化、逻辑清晰的自然语言对策，流式渲染于对话窗口中。这种“所问即所得”的深层交互机制，使得大模型技术真正在复杂的流域水环境调度业务中实现了工程化落地。

第 7 章 总结和展望

7.1 研究总结

流域水质变化过程受多种因素共同影响，既具有显著的时间依赖性，又表现出复杂的空间关联结构，同时还受到降雨、径流等气象水文条件的强烈驱动。如何在数据驱动框架下有效刻画水质演化的时空耦合特征，是当前流域水质预测研究中的关键问题之一。

围绕上述问题，本文以汉江流域为研究对象，系统开展了基于深度学习的流域水质预测研究，重点针对多站点、多变量水质数据的时空建模方法进行了探索。本文的主要研究工作和结论可总结如下：

（1）构建了面向流域水质预测的统一实验框架

本文基于国家水质自动监测站与 ERA5 气象再分析网格数据，通过严格的数据清洗与时空对齐操作，构建了涵盖多站点、多水质理化指标与气象强迫因子的长序列预测数据集。并通过合理的数据切分与标准化的评价指标体系（MSE、RMSE、MAE、MAPE），为后续复杂模型的训练与评估提供了坚实的数据底座。

（2）提出了一种气象感知的动态图时空预测模型

针对传统时空图神经网络普遍采用静态空间拓扑、难以适应汛期等非平稳水文条件变化的问题，本文创新性地引入气象驱动先验，设计了动态图生成机制。该机制打破了地理距离的刚性限制，使模型能够根据降雨、径流等气象特征的实时变化，自适应重构流域站点间的空间拓扑权重，精准捕捉水质污染物的动态输运过程。

（3）引入门控融合机制实现多源异构特征的有效协同

针对异质多源数据在物理量纲与统计分布上的差异，本文设计了物理感知门控单元，实现了气象特征与水质特征的自适应融合，有效过滤了外部环境噪声。同时，全面采用时间卷积网络替代传统循环结构，在规避长序列梯度衰减的同时大幅提升了并行计算效率。

（4）通过系统实验验证了模型的有效性与合理性

在宗关断面的多步长预测实验中，MD-DySTGCN 在各大核心误差指标上均实现了对先进时序大模型及传统时空图网络的超越。详细的消融实验充分验证了各核心模块的独立物理贡献；可视化分析进一步印证了模型在平稳期具备极高的保真度，在突发极端水文事件中具备敏锐的相位预警能力。

（5）设计并实现了基于大语言模型的水质智能预警系统

为跨越算法理论与工程落地的鸿沟，本文设计了一套集数据汇聚、在线推演与智能诊断于一体的综合决策平台。系统不仅完成了 MD-DySTGCN 算法的高并发在线部署，

还创新性地引入了基于大语言模型的智能体与检索增强生成架构,实现了异常水情的自动预警与基于自然语言的主动认知交互,打通了“数据感知-算法推演-智能决策”的完整业务闭环。

7.2 研究展望

尽管本文在流域水质时空预测算法构建与智能系统原型研发方面取得了实质性进展,但受限于研究周期与现有数据源瓶颈,本研究仍存在一些有待进一步深化与完善的方向:

(1) 气象驱动数据的时效性突破与实时预报介入

本文在构建气象驱动动态图时,主要依赖了 ERA5 气象再分析数据。尽管该数据在精度与空间分辨率上表现优异,极其适合历史模型的训练与机理验证,但其本质为后处理分析数据,存在固有的时间延迟。在真实的在线预警业务中,为实现真正意义上的超前预警,未来系统需接入实时数值天气预报以及高分辨率的雷达临近预报数据,以彻底消除气象特征的滞后性,提升系统在极端灾害天气下的前瞻研判能力。

(2) 物理机理与深度学习的深度融合

本文目前的 MD-DySTGCN 仍属于纯数据驱动范畴,尚未显式融合水动力学方程或水质降解动力学模型。未来研究可探索物理信息神经网络,将质量守恒与能量守恒等物理法则作为偏微分方程惩罚项引入损失函数,进一步提升预测模型在未知极端工况下的泛化能力与物理边界一致性。

(3) 面对极端长尾事件的稀疏建模增强

在特大暴雨、突发性化学品泄漏等极端情景下,水质突变往往呈现出剧烈的非线性特征。由于此类极端样本在历史数据中占比极小,模型容易产生回归均值的平滑效应。后续研究可引入长尾分布学习或极值理论,重塑损失函数的样本权重分配机制,以强化模型对低频、高危水文事件的捕捉精度。

(4) 大模型智能体的多模态感知与多智能体协同

本文当前的智能预警 Agent 主要依赖结构化的预测张量与文本预案进行逻辑推理。未来可进一步引入多模态大语言模型,赋予系统直接解析流域卫星遥感影像、无人机巡检视频的能力。此外,可探索构建多智能体协同框架,设立气象推演 Agent、水环境诊断 Agent 与法规调度 Agent 等垂类专家,通过群智博弈机制提升复杂应急事件下的辅助决策深度。

参考文献

- [1] 杨家宽,肖波,刘年丰,等.WASP6 水质模型应用于汉江襄樊段水质模拟研究[J].水资源保护,2005,(04):8-10.
- [2] 夏智宏,周月华,许红梅.基于 SWAT 模型的汉江流域水资源对气候变化的响应[J].长江流域资源与环境,2010,19(02):158-163.
- [3] 熊鸿斌,张斯思,匡武,等. 基于 MIKE 11 模型的引江济淮工程涡河段动态水环境容量研究[J].自然资源学报,2017,32(08):1422-1432.
- [4] 欧春平,夏军,王中根,等. 土地利用/覆被变化对 SWAT 模型水循环模拟结果的影响研究——以海河流域为例[J].水力发电学报,2009,28(04):124-129.
- [5] 徐志,牟亚莉,梁犁丽,等. 考虑协变量的随机森林降水融合算法在长江流域的应用[J].水电能源科学,2023,41(08):1-4.
- [6] 张雪芹.改进粒子群算法优化支持向量机的软件缺陷预测模型[D].湖州师范学院,2022.
- [7] 黎园园.基于多图卷积网络的河流总磷预测研究[D].电子科技大学, 2023.
- [8] 黎煜昭,刘启亮,邓敏,等. 基于物理约束 GRU 神经网络的河流水质预测模型[J]. 地球信息科学学报, 2023, 25(01):102-114.
- [9] 何欣.基于 GA-VMD-LSTM 的河流水质预测模型的研究与应用[D]. 华中科技大学, 2022.
- [10] 罗文显.基于深度学习的水质时间序列预测技术及其应用研究[D]. 浙江农林大学, 2024.
- [11] 陈志伟. 基于时空图卷积网络 (STGCN) 的河流水质预测模型构建及应用[D]. 哈尔滨工业大学, 2023.
- [12] Rajagopal S ,Ganesh S S ,Karthick A , et al. Environmental water quality prediction based on COOT-CSO-LSTM deep learning[J].Environmental science and pollution research international,2024,31(42):1-9.
- [13] Zhao Z ,Fan B ,Zhou Y . An Efficient Water Quality Prediction and Assessment Method Based on the Improved Deep Belief Network—Long Short-Term Memory Model[J].Water,2024,16(10).
- [14] Zheng Z ,Ding H ,Weng Z , et al. Research on out-of-sample prediction method of water quality parameters based on dual-attention mechanism[J].Environmental Modelling and Software,2024,176106020-.
- [15] Li W ,Zhao Y ,Zhu Y , et al. Research progress in water quality prediction based on deep learning technology: a review.[J].Environmental science and pollution research international,2024,31(18):26415-26431.

- [16] Markus R ,Gustau C ,Bjorn S , et al. Deep learning and process understanding for data-driven Earth system science[J].Nature,2019,566(7743):195-204.
- [17] Abbaspour K ,Rouholahnejad E ,Vaghefi S , et al. A continental-scale hydrology and water quality model for Europe: Calibration and uncertainty of a high-resolution large-scale SWAT model[J].Journal of Hydrology,2015,524:733-752.
- [18] Gassman W P ,Reyes R M ,Green H C , et al. The Soil and Water Assessment Tool: Historical Development, Applications, and Future Research Directions[J].Transactions of the ASABE,2007,50(4):1211-1250.
- [19] Abdessamad E ,Nourddine E ,Kumar S B , et al. Advanced machine learning models for robust prediction of water quality index and classification[J].Journal of Hydroinformatics,2025,27(2):299-319.
- [20] Mo Y ,Xu J ,Liu C , et al. Assessment and prediction of Water Quality Index (WQI) by seasonal key water parameters in a coastal city: application of machine learning models[J].Environmental Monitoring and Assessment,2024,196(11):1008-1008.
- [21] Maier R H ,Dandy C G . Neural networks for the prediction and forecasting of water resource variables: a review of modelling issues and applications[J].Environmental Modelling and Software,2000,15(1):101-124.
- [22] Chen J ,Wei X ,Liu Y , et al. Deep Learning for Water Quality Prediction—A Case Study of the Huangyang Reservoir [J]. Applied Sciences, 2024, 14 (19): 8755-8755.
- [23] S. G N ,Frederik K ,Keefe A S , et al. What Role Does Hydrological Science Play in the Age of Machine Learning? [J]. Water Resources Research, 2021, 57 (3).
- [24] Lin F ,Li X ,Su Y , et al. Water quality prediction model based on improved long short-term memory neural network and empirical mode decomposition [J]. Discover Artificial Intelligence, 2025, 5 (1): 199-199.
- [25] Li D ,Liu L ,Ji X . A Long-term precise prediction model for water quality in aquaculture based on an adaptive decomposition Transformer [J]. Applied Soft Computing, 2025, 182 113548-113548.
- [26] Alizamir M ,Heddami S ,Kim S . A robust and explainable deep learning model based on an LSTM-CNN framework for reliable FDOM prediction in water quality monitoring: Incorporating SHAP analysis for enhanced interpretability [J]. Process Safety and Environmental Protection, 2025, 201 (PB): 107594-107594.
- [27] Liu L ,Ji X ,Duan B , et al. A long-term prediction model for key water quality based on transformer with parallel attention mechanism and adaptive spectral enhancement. [J]. Environmental geochemistry and health, 2025, 47 (8): 322.
- [28] Jung J ,Park T ,Park J , et al. A river network model using a weight-based merged LSTM for multi-source monitoring integration [J]. Ecological Informatics, 2025, 90 103320-103320.
- [29] Hasani A ,Ghorbani A M ,Darbandi S . Enhancing Predictions of Surface Water Quality Through the Integration of Deep Learning and Time Series Analysis

- Techniques [J]. Water Conservation Science and Engineering, 2025, 10 (2): 78-78.
- [30] Liu J ,Wu P ,Qin M , et al. A holistic assessment and prediction of water quality in Hulan River Estuary Wetland Nature Reserve: parameters, pollution indices and modeling [J]. Wetlands Ecology and Management, 2025, 33 (4): 57-57.
- [31] Xu Y ,Liu Z . Research on water quality prediction of Jiangshan Port based on SCV-CBA model. [J]. Scientific reports, 2025, 15 (1): 24474.
- [32] Gao Z ,Wang G ,Zhu Y , et al. Prediction of Water Quality Parameters and Pollution Exceedance Analysis in Typical Rivers of Semi-Arid Regions Based on Interpretable Deep Learning Models. [J]. Environmental pollution (Barking, Essex : 1987), 2025, 383 126801.
- [33] Shao K ,Li D ,Tang H , et al. Improving multi-step dissolved oxygen prediction in aquaculture using adaptive temporal convolution and optimized transformer [J]. Computers and Electronics in Agriculture, 2025, 235 110329-110329.
- [34] Das A . Prediction of Urban Surface Water Quality Scenarios Using Water Quality Index (WQI), Multivariate Techniques, and Machine Learning (ML) Models in Water Resources, in Baitarani River Basin, Odisha: Potential Benefits and Associated Challenges [J]. Earth Systems and Environment, 2025, (prepublish): 1-37.
- [35] Chen X ,Zhao C ,Chen J , et al. Water quality parameters-based prediction of dissolved oxygen in estuaries using advanced explainable ensemble machine learning. [J]. Journal of environmental management, 2025, 380 125146.
- [36] Setiyanti M ,Hoendarto G ,Tjen J . Enhancing Water Potability Identification through Random Forest Regression and Genetic Algorithm Optimization [J]. Engineering Headway, 2025, 18 101-110.
- [37] Jain S ,Bawa A ,Mendoza K , et al. Enhancing prediction and inference of daily in-stream nutrient and sediment concentrations using an extreme gradient boosting based water quality estimation tool - XGBest. [J]. The Science of the total environment, 2025, 963 178517.
- [38] Zhao S ,Liu R ,Liu Y , et al. A Water Quality Prediction Model Based on Modal Decomposition and Hybrid Deep Learning Models [J]. Water, 2025, 17 (2): 184-184.
- [39] Alharbi H A ,Rizk H F ,Gaber S K , et al. Hybrid deep learning optimization for smart agriculture: Dipper throated optimization and polar rose search applied to water quality prediction. [J]. PloS one, 2025, 20 (7): e0327230.
- [40] Qi B L ,Jie D Z ,Yang Z , et al. Comparative analysis of supervised learning models for effluent quality prediction in wastewater treatment plants. [J]. PloS one, 2025, 20 (6): e0325234.
- [41] Sigit S . Trends and gaps in ai - driven predictive models for coastal water quality: A bibliometric study [J]. BIO Web of Conferences, 2025, 188 04004-04004.
- [42] Jing J ,Quan P . A Review of Research on Intelligent Modeling Approaches for Rural Wastewater Quality Prediction [J]. Procedia Computer Science, 2025, 266 1096-1101.

- [43] Zhang S ,Omar H A ,Hashim S A , et al. Enhancing waste management and prediction of water quality in the sustainable urban environment using optimized algorithm of least square support vector machine and deep learning techniques [J]. *Urban Climate*, 2024, 58 102095-102095.
- [44] Wang X ,Li Y . Prediction of mine water quality by the Seq2Seq model based on attention mechanism [J]. *Heliyon*, 2024, 10 (18): e37916-e37916.
- [45] Chen L ,Zhang Y ,Xu B , et al. A Lot-Based VMD-CNN-BIGRU Indoor Mariculture Water Quality Prediction Method Including Attention Mechanism [J]. *International Journal of High Speed Electronics and Systems*, 2024, 34 (03).
- [46] Sheik G A ,Malla A M ,Srungavarapu S C , et al. Prediction of wastewater quality parameters using adaptive and machine learning models: A South African case study [J]. *Journal of Water Process Engineering*, 2024, 67 106185-106185.
- [47] Afan A H ,Mohtar W M H W ,Khaleel F , et al. Data-driven water quality prediction for wastewater treatment plants [J]. *Heliyon*, 2024, 10 (18): e36940-e36940.
- [48] Zheng H ,Hou S ,Liu J , et al. Advanced Machine Learning and Water Quality Index (WQI) Assessment: Evaluating Groundwater Quality at the Yopurga Landfill [J]. *Water*, 2024, 16 (12): 1666-1666.
- [49] Fooladi M ,Nikoo R M ,Mirghafari R , et al. Robust clustering-based hybrid technique enabling reliable reservoir water quality prediction with uncertainty quantification and spatial analysis. [J]. *Journal of environmental management*, 2024, 362 121259-121259.
- [50] Cruz L D C E J ,Mamani A W ,Pineda F , et al. A Review on Artificial Intelligence for Water Quality Prediction in Amazonian Countries [J]. *Nature Environment and Pollution Technology*, 2024, 24 (2): D1705-.
- [51] Kushwaha L N ,Kudnar S N ,Vishwakarma K D , et al. Stacked hybridization to enhance the performance of artificial neural networks (ANN) for prediction of water quality index in the Bagh river basin, India [J]. *Heliyon*, 2024, 10 (10).
- [52] A. A T . Prediction of Water Quality in Designed Reservoir: How to Improve the Cooperation Between Designers and Experts [J]. *Power Technology and Engineering*, 2024, 57 (6): 827-830.
- [53] Rahaman H M ,Sajjad H ,Hussain S , et al. Surface water quality prediction in the lower Thoubal river watershed, India: A hyper-tuned machine learning approach and DNN-based sensitivity analysis [J]. *Journal of Environmental Chemical Engineering*, 2024, 12 (3): 112915-.
- [54] Fu W ,Feng M ,Guo C , et al. Machine learning-driven prediction of phosphorus removal performance of metal-modified biochar and optimization of preparation processes considering water quality management objectives. [J]. *Bioresource technology*, 2024, 403 130861-130861.
- [55] Li M ,Wang D ,Xu R , et al. A Variational Mode Decomposition Analysis and

- Prediction Simulation of DO in the Water Environment of the Chengdu Area, China [J]. *Water*, 2024, 16 (10).
- [56] Jiao J ,Ma Q ,Huang S , et al. A hybrid water quality prediction model based on variational mode decomposition and bidirectional gated recursive unit. [J]. *Water science and technology : a journal of the International Association on Water Pollution Research*, 2024, 89 (9): 2273-2289.
- [57] Cai R ,Hu M ,Geng X , et al. Prediction of Diffuse Attenuation Coefficient Based on Informer: A Case Study of Hangzhou Bay and Beibu Gulf [J]. *Water*, 2024, 16 (9): DOI:10.3390/W16091279.
- [58] Yu Y ,Chen Y ,Huang S , et al. Enhancing long-term river water quality prediction: Construction and validation of an improved hybrid model [J]. *Process Safety and Environmental Protection*, 2024, 186 388-398.
- [59] M K ,C P R S V ,J A V , et al. Prediction of ground water quality in western regions of Tamilnadu using LSTM network [J]. *Groundwater for Sustainable Development*, 2024, 25 101156-.
- [60] Huang S ,Xia J ,Wang Y , et al. Water quality prediction based on sparse dataset using enhanced machine learning [J]. *Environmental Science and Ecotechnology*, 2024, 20 100402-.
- [61] K. M N ,E. G ,Lawanya M S , et al. Reliable water quality prediction and parametric analysis using explainable AI models [J]. *Scientific Reports*, 2024, 14 (1): 7520-7520.
- [62] Xu T ,Ma W ,Chen J , et al. Water Quality of Lake Erhai in Southwest China and Its Projected Status in the near Future [J]. *Water*, 2024, 16 (7).
- [63] Abbas F ,Cai Z ,Shoaib M , et al. Machine Learning Models for Water Quality Prediction: A Comprehensive Analysis and Uncertainty Assessment in Mirpurkhas, Sindh, Pakistan [J]. *Water*, 2024, 16 (7).
- [64] Jongjaraunsuk R ,Taparhudee W ,Suwannasing P . Comparison of Water Quality Prediction for Red Tilapia Aquaculture in an Outdoor Recirculation System Using Deep Learning and a Hybrid Model [J]. *Water*, 2024, 16 (6): 907-.
- [65] Jiange J ,Qianqian M ,Fanglin L , et al. A hybrid prediction model of dissolved oxygen concentration based on secondary decomposition and bidirectional gate recurrent unit [J]. *Environmental Geochemistry and Health*, 2024, 46 (4): 127-127.
- [66] Mellal H E N ,Tahar W ,Boumaaza M , et al. Prediction of purified water quality in industrial hydrocarbon wastewater treatment using an artificial neural network and response surface methodology [J]. *Journal of Water Process Engineering*, 2024, 58 104757.
- [67] Yongkai H ,Yiling C . Prediction of Total Phosphorus Based on Distance Correlation and Machine Learning Methods—a Case Study of Dongjiang River, China [J]. *Water, Air, & Soil Pollution*, 2024, 235 (2).
- [68] Yan X ,Zhang T ,Du W , et al. A Comprehensive Review of Machine Learning for

- Water Quality Prediction over the Past Five Years [J]. *Journal of Marine Science and Engineering*, 2024, 12 (1).
- [69] Yao K ,Chen Y ,Li Y , et al. Water Quality Prediction of Small-Micro Water Body Based on the Intelligent-Algorithm-Optimized Support Vector Machine Regression Method and Unmanned Aerial Vehicles Multispectral Data [J]. *Sustainability*, 2024, 16 (2).
- [70] Yuwen Z ,Sha L ,Zhirui Z , et al. Predictions of heavy metal concentrations by physiochemical water quality parameters in coastal areas of Yangtze river estuary [J]. *Marine Pollution Bulletin*, 2024, 199 115951-.
- [71] Dong L ,Zuo X ,Xiong Y . Prediction of hydrological and water quality data based on granular-ball rough set and k-nearest neighbor analysis. [J]. *PloS one*, 2024, 19 (2): e0298664-e0298664.
- [72] Jaegyu S ,Seokmin H ,Jiye L , et al. Deep learning with data preprocessing methods for water quality prediction in ultrafiltration [J]. *Journal of Cleaner Production*, 2023, 428.
- [73] Priyanka C ,Xiyu C ,Yichen F , et al. Water quality prediction of salton sea using machine learning and big data techniques [J]. *International Journal of Environmental Analytical Chemistry*, 2023, 103 (18): 6835-6858.
- [74] Jinghan D ,Zhaocai W ,Junhao W , et al. A water quality prediction model based on signal decomposition and ensemble deep learning techniques. [J]. *Water science and technology : a journal of the International Association on Water Pollution Research*, 2023, 88 (10): 2611-2632.
- [75] Hossein M ,Poogitha J ,Ken-Tye Y , et al. Efficient water quality prediction by synthesizing seven heavy metal parameters using deep neural network [J]. *Journal of Water Process Engineering*, 2023, 56 DOI:10.1016/J.JWPE.2023.104349.
- [76] Jing B ,Zexian C ,Haitao Y , et al. Accurate water quality prediction with attention-based bidirectional LSTM and encoder – decoder [J]. *Expert Systems With Applications*, 2024, 238 (PC).